人工智慧在資安應用趨勢之研究

李睿軒 徐國鈞
國立臺北商業大學
juihsuanlee@ntub.edu.tw

摘要

隨著資安領域所面對的攻擊樣態快速更迭、日益複雜。使得傳統的資安防禦措施越來越難以應對新型態的資安風險。與此同時人工智慧(Artificial Intelligence, AI)相關的技術突破，其應用在各個領域持續蓬勃發展，也為資安領域帶來進步的可能性。因此越來越多研究將人工智導入資安領域，以提高防護與面對風險的能力。

然而，儘管人工智慧技術在資安應用中展現巨大潛力，但這一領域仍面對諸多挑戰。為了更好理解人工智慧在資安領域的應用現況與未來發展方向，本文採用系統性文獻回顧(Systematic literature review)的方法，綜合分析近年來的相關研究。本文旨在通過系統性地整理及分析現有文獻，總結人工智慧在資安應用中的主要趨勢，並識別出該領域未來可能的研究方向與實務應用可能面臨到的挑戰。

關鍵詞：人工智慧、資安、機器學習、深度學習

1. 前言

1.1 研究背景

近年來，隨著數位化轉型和物聯網等領域快速發展，現代生活對資通技術(Information and Communication Technology, ICT)與網路的依賴日益加深，同時資安領域所面對的攻擊樣態快速更迭、日益複雜化。迅速增加與多樣態的攻擊使得傳統的資安防禦措施面對極大的挑戰。

1.2 研究動機

儘管現有的資案技術已非常成熟，但面對新型態的攻擊模式使得傳統的資安防禦措施越來越難以應對新型態的資安風險，迫使防禦方式需要頻繁更新以應對不同的攻擊模式，導致防護效果出現侷限性。與此同時人工智慧技術隨著深度學習、機器學習等技術突破，其應用在各個領域持續蓬勃發展，也為資安領域帶來進步的可能性。人工智慧技術可應用在網路入侵檢測(Intrusion Detection System, IDS)、異常流量分析(Anomaly Traffic Analysis)、高階持續性威脅(Advanced Persistent Threat, APT)預測等資安應用上。因此越來越多研究將人工智導入資安領域，以提高資安防護能力。然而，儘管人工智慧技術在資安應用中展現巨大潛力，但這一領域仍面對諸多挑戰，如：數據稀缺性、高誤報率、模型可解釋性及跨領域技術整合困難等問題。

1.3 研究目的

為了更好理解人工智慧在資安領域的應用現況與未來發展方向，本文採用系統性文獻回顧的方法，綜合分析近年來的相關研究。本文旨在通過系統性地整理及分析現有文獻，總結人工智慧在資安應用中的主要趨勢，並分析該領域未來可能的研究方向與實務應用可能面臨到的挑戰。

1.4 研究流程

本研究的結構如下：第二章為文獻探討，探討人工智慧在資安領域中的應用現況與相關研究。第三章為研究方法，描述本文如何使用系統性文獻回顧的方法進行研究。第四章為資料分析與討論，對所收集的文獻資料進行內容分析。最後，第五章為研究結論，總結目前人工智慧在資安領域的研究趨勢並提出未來研究的方向與挑戰。

2. 文獻探討

2.1 人工智慧(artificial intelligence)

人工智慧是模擬人類行為的一種電腦科學技術。其包含了機器學習與深度學習等多種方法。人工學習的目的是通過模擬與增強人類的認知能力來解決複雜的問題。隨著近年發展，人工智慧技術已廣泛運用在各個領域，如自動駕駛、金融風險管理等。

2.2 機器學習(machine learning, ML)

機器學習是人工智慧的一個分支。機器學習不需明確程式設計，而是通過數據去自動學習並能進行預測或決策。機器學習主要分為四種：監督式學習(supervised learning)、非監督式學習(unsupervised learning)、半監督式學習(semi-supervised learning)和強化學習(reinforcement learning)。

監督式學習在模型訓練的過程中所使用的數據是帶有標籤的數據。也就是每組數據都包含一個特徵向量與相對應的目標變量(正確輸出)。模型的目標是學習從特徵向量到目標變量的映射，從而能準確地預估新數據的結果。

非監督式學習與監督式學習的差別是其使用的數據沒有標籤(目標變量)，代表每組數據僅有特徵向量。非監督式學習的目標在學習數據間的結構與模式，如分群(clustering)、降維(dimensionality reduction)等。

半監督式學習是一種結合了監督式學習與非監督式學習的機器學習方法。在半監督式學習中，模型使用少量有標籤的數據與大量無標籤的數據進行訓練。此方法適用於難以獲得大量有標籤的數據時進行模型訓練。

強化學習則是通過該模型與環境交互來學習最佳策略的方法。模型的每個選擇會得到獎勵或懲罰，而模型則會根據所受到的獎勵與懲罰更新策略，目標是獲得最大化累積獎勵。其優點在訓練模型不需要預先準備數據集，而是通過與環境互動來學習。

2.3 深度學習(deep learning, DL)

深度學習是機器學習的其中一種。其概念源自於人工神經網路(artificial neural networks, ANN)，透過使用多層神經網路來處理數據，每層神經元(neuron)接收來自上層神經元的輸入，經過加權與激勵函數後將產生輸出並傳遞到下一層。整個神經網路通過訓練更新神經元的權重，使其減少與預估值的誤差。深度學習技術包含卷積神經網路(convolutional neural networks, CNN)[1]、循環神經網路(recurrent neural networks, RNN)[2]和生成對抗網路(generative adversarial networks, GAN)[3]等。

卷積神經網路(CNN)是利用卷積層(convolutional layer)提取局部特徵，並使用池化層(pooling layer)減少特徵維度，最後透過全連通層(fully connected layer)進行分類。常用於圖像分析領域。

循環神經網路(RNN)是專門處理序列數據的神經網路架構。RNN 的隱藏層(Hidden layer)會接收當前的輸入與前一次的隱藏狀態，並通過激勵函數計算新的隱藏狀態。這種設計使得 RNN 具有記憶能力，能夠學習序列數據的前後關係，常用於自然語言處理(natural language processing, NLP)及語音辨識等序列數據預測。

生成對抗網路(GAN)由生成器(generator)與判別器(discriminator)兩個神經網路組成。生成器的目標是最大化判別器對生成數據的錯誤識別率，而判別器的目標是最小化錯誤分辨的機率。GAN 藉有這兩個神經網路之間的對抗訓練，使得生成器最終能生成逼真的數據。常用於圖像生成相關領域。

2.4 入侵檢測系統(IDS)

入侵檢測系統的運作原理是監控並分析基於網路(NIDS)或主機(HIDS)的流量，並對偵測到的潛在入侵發出警示或採取主動防禦行為。其檢測方式主要分為兩種：簽章基礎檢測(signature-based IDS)及異常基礎檢測(anomaly-based IDS)。其中，簽章基礎檢測會根據已知的惡意軟體樣態或序列作為簽章，並將簽章匹配流量進行檢測。此方法可以輕易地檢測出已知的攻擊型態，也不會有錯誤檢測的狀況。而異常基礎檢測會檢查行為樣態並依此對正常行為建立模型，並以此模型檢測異常流量。此方法將任何偏離正常行為模式的事件都視為潛在威脅，可以檢測出未知的攻擊與威脅，但容易產生較高的誤報率(false alarm rate)。

2.5 文獻回顧研究

在本研究中，針對人工智慧在資安領域的發展進行了系統性文獻回顧，通過對相關文獻的篩選與分析，識別出目前主要的研究趨勢與方向。近年來，由於人工智慧技術高度發展，深度學習與機器學習在資安領域的應用越來越廣泛，特別是在入侵檢測系統(IDS)方面有許多相關文獻，也展現出極高的發展潛力。

在入侵檢測系統方面，由於傳統的兩種檢測方式都有其明顯的缺點，因此 Iqbal H. Sarker、Yoosef B. Abushark、Fawaz Alsolami 及 Asif Irshad Khan 利用機器學習，基於一個入侵數據集(intrusion dataset)中多個網路流量與系統活動的相關特徵訓練一個樹狀結構的入侵檢測模型(IntruDTree)[4]。並分析每個特徵的重要性後，通過降低特徵維度來減少模型的計算複雜度。最後，通過實驗分析，如圖1，此模型在精確率(precision)、召回率(recall)及 F-score 等各指標都優於其他機器學習模型。

另外 Amir Haider、Muhammand Adnan、Abdur Rehman、Muhib Ur Rahman 和 Hyung Seok Kim 結合深度極限學習機(deep extreme learning machine, DELM)與即時序列學習(real-time sequential learning)技術提出 RTS-DELM-CSIDS (real-time sequential deep extreme learning machine cybersecurity intrusion detection system)框架來優化異常基礎檢測[5]。如圖2，此框架使用 NSL-KDD 數據集與即時數據集(real-time dataset)同時訓練來建立人工神經網路(ANN)模型，(RTS-DELM)。此框架的優點是相較於傳統的異常基礎檢測，該模型能通過持續學習的機制來降低誤報率，該模型在訓練階段的準確率達到96.22%，驗證階段的準確率也有92.73%。

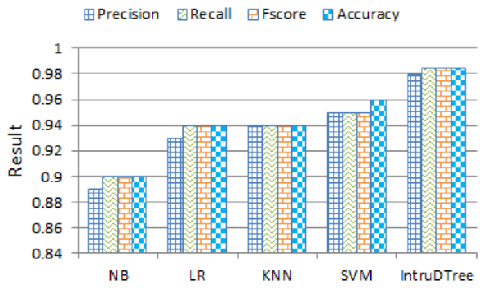

圖 1 不同機器學習安全模型的有效性比較

資料來源：Iqbal H. Sarker, 2020

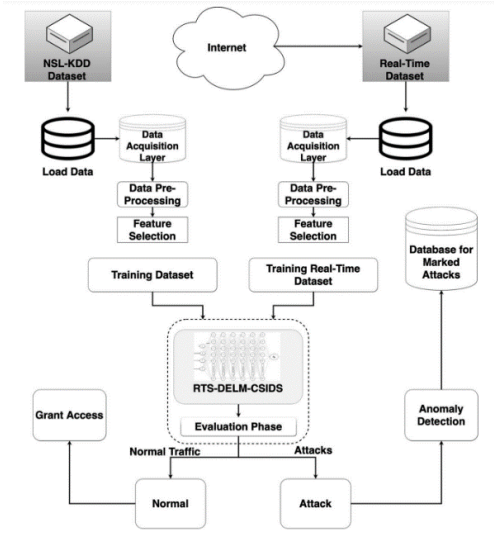

圖 2 RTS-DELM-CSIDS 架構

資料來源：Amir Haider, 2021

而 Yazan Otoum、Dandan Liu 和 Amiya Nayak 提出專門用於保護物聯網環境的入侵檢測系統框架(DL-IDS)[6]，如圖3。DL-IDS 框架是基於深度學習的入侵檢測系統，其包含三個階段：預處理階段(Preprocessing Phase)、最佳化特徵選擇階段(Optimal Feature Selection Phase)與分類階段(Classification Phase)。預處理階段會將數據集去除不確定與相似度過高的冗餘數據。最佳化特徵選擇階段則會通過特徵選擇演算法來提取數據集中的最佳特徵，從而減少學習時間並提高準確性，其中 DL-IDS 框架採用蜘蛛猴優化(Spider Monkey Optimization, SMO)演算法來實現最佳特徵選擇。最後，分類階段中 DL-IDS 使用堆疊深度多項式網路(Stacked-Deep Polynomial Network, SDPN)進行數據分類。DL-IDS 框架在實驗中的表現均優於現有其他模型，如圖4所示，有效提高物聯網環境下的安全防護能力。

由上述文獻內容可以發現目前人工智慧對於入侵檢測系統(IDS)的應用主要是利用不同的模型與框架的設計，發展高準確率、低誤報率的入侵檢測系統。

3. 研究方法

3.1 系統性文獻回顧概述

為了能夠全面與系統性地了解近年人工智慧在資安領域應用的趨勢。本研究以系統性文獻回顧的方法搜尋文獻資料。系統性文獻回顧的目的是通過預先定義好的流程，識別、篩選和分析所有相關文獻。且系統性文獻回顧需要明確定義每個流程的細節，包含但不限於搜索策略、篩選標準等。

其中有兩個階段。第一階段中確定了搜尋使用的資料庫與關鍵字，以獲得初步的文獻清單。第二階段則是對初步的文獻清單訂定篩選標準與內容分析，選擇與本研究最相關的文獻，並分析其內容。

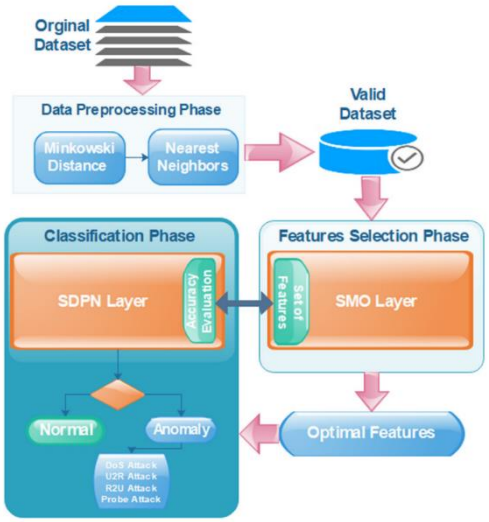

圖 3 DL-IDS 架構

資料來源：Yazan Otoum, 2022

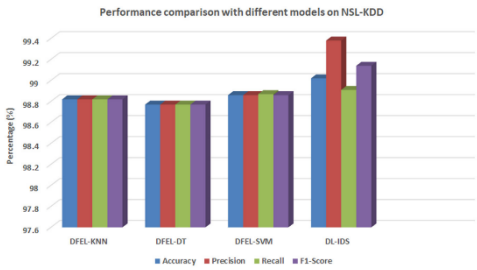

圖 4 DL-IDS 與其他模型比較

資料來源：Yazan Otoum, 2022

3.2 資料庫選擇與關鍵字設計

在第一階段中，首先先選擇文獻搜尋的資料庫，使用 Web of Science 作為主要的資料庫來進行文獻搜尋，因為它涵蓋了各個期刊中的相關文獻，能更廣泛地搜索到更多文獻資料。接下來決定關鍵字組合搜尋時，參考 Zeeshan Ahmad 所使用的搜尋方法[7]，如圖4。最後決定使用人工智慧(Artificial Intelligence)與網路安全(Cybersecurity)相關的關鍵字對 Title、Keyword 與 Abstract 做搜尋，得出初始清單共1416筆文獻。

3.3 文獻篩選流程與標準

接下來為了能從初始清單中進一步篩選此領域較具影響力且能代表近年研究趨勢的文獻。將篩選條件社為近五年(2019-2024)引用數(WoS Core)

超過100次的文獻，並通過閱讀標題與摘要排除非相關領域的1篇文獻後，最終篩選出20篇核心文獻進行深入內容分析。

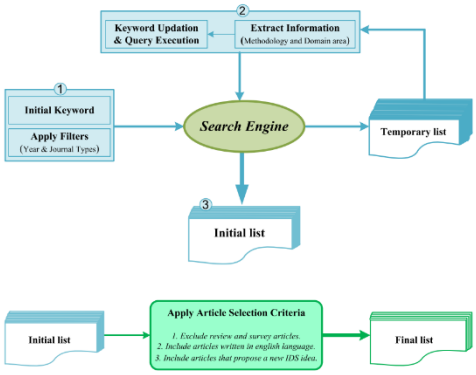

圖 4 文獻清單搜尋方法

資料來源：Zeeshan Admad, 2020

本研究採用了 PRISMA (Preferred Reporting Items for Systematic Reviews and Meta-Analyses)流程圖來展示文獻篩選過程，如圖5所示。此流程圖包含文獻蒐集的流程與對應的文獻數量。確保文獻篩選過程的透明性與可重複性。

首先，在識別(identification)階段中，我們利用關鍵字搜索與初步篩選後，從數據庫(Web of Science)中識別出1416篇文獻。接著，再篩選(screening)階段中，通過引用數(不少於100次)作為篩選標準及排除非相關領域的文獻。在此階段共有1396篇文獻被排除，剩餘的20篇文獻進行進一步的全文閱讀。最後，在納入(included)階段中，對剩餘20篇文獻進行全文評估，以確定這些文獻是否符合研究的納入標準。而這20篇文獻經過評估後皆被納入本次系統性文獻回顧中，這些文獻不僅與本研究領域高度相關，且具有足夠的研究水準與數據完整性，因此可用於後續的內容與主題分析。

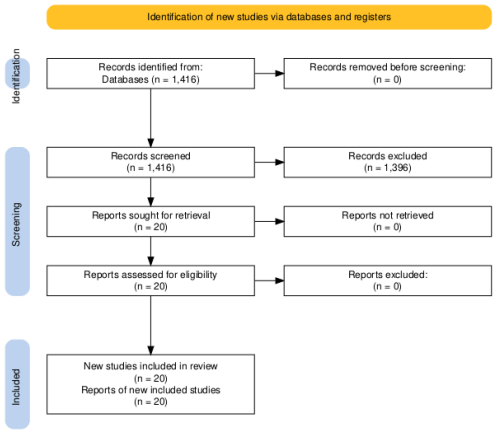

圖 5 PRISMA 流程圖

資料來源：本研究自行整理

3.4 文獻篩選流程與標準

本研究主要採用內容分析(Content analysis)與主題分析(Thematic analysis)兩種分析方法。

內容分析為一種用於系統化地分析文本內容與數據的質性分析方法。可識別出文獻中重複出現的主題與內容。在本研究中，對篩選出的20篇核心文獻進行全文閱讀後，針對其研究領域、使用技術與研究成果進行編碼。

主題分析是在內容分析的基礎上，進一步識別與分析文獻中關鍵的研究主題。本研究使用此方法找出近年來人工智慧技術應用在資安領域的核心議題，如：入侵檢測系統、異常檢測、威脅預測等，並探討不同研究在這些主題中的成果。

4. 資料分析與討論

4.1 關鍵字分析

通過系統性文獻回顧並篩選出近五年的1191篇文獻，在合併相似關鍵字(Author keywords)如intrusion detection 與 intrusion detection system 後，對其進行統計，如圖6，發現人工智慧(artificial intelligence)相關關鍵字包含機器學習(machine learning)、深度學習(deep learning)，出現次數最高。而資安領域相對廣泛的關係，關鍵字出現頻率相較於人工智慧相關關鍵字低。但其中入侵檢測(intrusion detection)出現次數最高。可能是因為傳統的入侵檢測系統如簽章基礎檢測與異常基礎檢測都有明顯的缺點，對於人工智慧的需求較高。同時入侵檢測系統所需要的入侵數據集資料相對完整，更方便於人工智慧模型訓練。另外可以發現物聯網(internet of things)出現頻率也有113次，顯示近年物聯網的快速發展使得其對資安的需求提升，促使相關的研究增加。

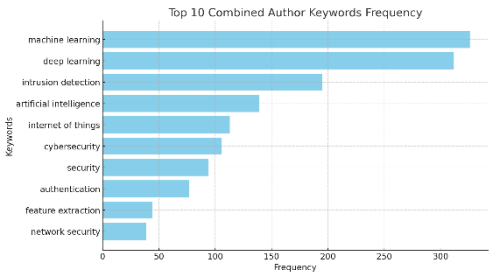

圖 6 關鍵字次數分析

資料來源：本研究自行整理

圖7為關鍵字與年份進行交叉分析，在觀察這10個關鍵字在近五年的變化趨勢後，本研究發現大部分關鍵字的頻率在近五年都持續增加，其中機器學習(machine learning)與深度學習(deep learning)這兩個關鍵字不僅在每個年份中的出現頻

率最高，且增加的幅度也最為顯著。而資安領域的入侵偵測(intrusion detection)與物聯網(internet of things)的增長趨勢也相對明顯，這顯示了近年人工智慧在資安領域的應用的主要發展方向。此外，特徵提取(feature extraction)這個關鍵字雖然出現的頻率較低，但其在近年中保持相對穩定的趨勢，這可能是因為資安領域在使用數據時大多需要即時性，過多的特徵輸入會導致模型訓練與響應速度地下降。因此，在資安領域應用人工智慧時，往往需要提取少數相對重要的特徵來訓練模型與做出判斷。這也解釋了為何特徵提取相關的研究仍在持續進行。

對關鍵字數量與趨勢進行分析後，可以為理解當前人工智慧在資安領域的研究方向與趨勢提供許多的參考價值。同時，也能理解此領域未來可能的研究方向。例如：隨著安全威脅的多樣化與複雜化，未來研究可以更加深入探討如何優化機器學習與深度學習的模型，以提高其在入侵檢測的準確性。此外，隨著物聯網設備的普及，如何有效地保護這些設備免受網路攻擊也成為一個重要的研究課題。

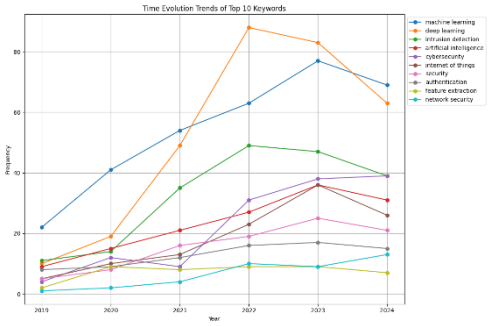

圖 7 關鍵字年份交叉分析

資料來源：本研究自行整理

4.2 內容與主題分析

通過系統性文獻回顧所得到的初始文獻清單中的1471篇文獻，對其發表年代(Publication year)進行分析，如圖7所示，發現在2019年以前，每年人工智慧應用於資安領域的文獻不超過25篇。而從2019年開始，除了每年所發表的文獻都在90篇以上，文獻數量也逐年快速上升至2023年的326篇。此領域文獻數量的變化，主要是因近年人工智慧領域的蓬勃發展與資安需求的增長，使相關研究的數量也快速增加。

針對系統性文獻回顧方法篩選出的20篇核心文獻進行全文閱讀後，發現大多數研究集中於入侵檢測系統(IDS)、深度學習在資安中的應用、物聯網安全。

IDS 作為多數文獻主要研究的內容，IDS 研究的方向主要是通過創新的機器學習模型解決傳統入侵檢測系統存在的高誤報率及低檢測率的問題。而未來如何在更多樣化的網路環境與面對更多變的攻擊方式時能更精準地識別威脅，仍是研究的重點之一。

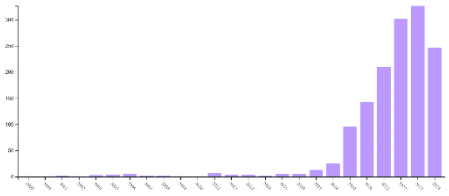

圖 8文獻年代分析

資料來源：Web of Science

深度學習技術，尤其是卷積神經網路(CNN)與生成對抗網路(GAN)，在文獻中多次被提及。CNN 技術能對惡意軟體進行分類，對於檢測惡意軟體有很好的應用。而 GAN 在資安領域則可用來生成高品質的入侵數據集，以補充真實數據的不足，可提高模型的準確率與對未知威脅的應對能力。

由於物聯網設備數量在近年快速增加與普及，如何建立保護這些設備的模型成為熱門的研究主題。許多基於深度學習的異常檢測模型已經成為確保物聯網設備安全的主要手段之一。

5. 研究結論

本研究通過系統性文獻回顧，對人工智慧在資安領域的應用現況與未來趨勢進行深入探討。文獻分析後顯示機器學習與深度學習已經成為現代資安防護的重要工具，特別是在入侵檢測系統(IDS)和物聯網(IoT)的威脅檢測中展現出巨大的應用潛力。

其中深度學習在資安領域中的應用取得了重要進展，例如：卷積神經網路(CNN)、長短期記憶(LSTM)等先進技術在惡意軟體與異常行為檢測方面展示非常好的性能。如基於 Transformer 的 BERT 模型[8]特別擅長處理 APT(Advanced Persistent Threat)攻擊。此外，深度學習還被應用於軟體定義網路(Software Defined Networking, SDN)架構下的 NIDS[9]，也能達到提高檢測準確性與反應速度的效果。

在工業物聯網(IIoT)安全領域，深度學習技術結合傳統的網路檢測方式[9]，除了能有效地應用於 IIoT 的 APT 攻擊檢測，能夠在長期持續的公及序列中保持很好的表現外，也能夠隨著威脅的變化自行適應與調整，提高系統的防護能力。

儘管人工智慧在資安領域的應用已十分廣泛，也取得了顯著的成果。仍然存在許多挑戰要克服，例如：數據稀缺性、模型的可解釋性與跨領域整合等。這些問題使得目前人工智慧技術沒辦法大規模應用在資安領域。此外，應對越來越複雜且多變的網路環境，如何提高模型的泛化能力與即時性仍是需要優化的地方。

總結來說，人工智慧技術，尤其是深度學習，已經在資安領域發揮一定的作用。若未來能通過克服現有的技術挑戰，這些技術能夠在資安領域能有更廣泛的應用，同時也能提升網路安全的防護能力。

參考文獻

[1] Keiron O'Shea and Ryan Nash, "An introduction to convolution neural networks,"arXiv preprint arXiv:1511.08458, Nov 2015

[2] Medsker, Larry R. amd Lakhmi Jain, "Recurrent neural networks," Design and Applications 5.64-67, 2001

[3] Antonia Creswell, Tom White, Vincent Dumoulin, Kai Arulkumaran, Biswa Sengupta and Anil A. Bharath, "Generative adversarial networks: an overview," IEEE signal processing magazine, vol. 35, no. 1, pp. 53-65, Jan 2018

[4] Iqbal H. Sarker, Yoosef B. Abushark, Fawaz Alsolami and Asif Irshad Khan, "IntruDTree: a machine learning based cyber security intrusion detection model," Summary, vol. 12, no. 5, pp. 754–768, May 2020.

[5] Amir Haider, Muhammad Adnan Khan, Abdur Rehman, Muhib Ur Rahman and Hyung Seok Kim, "A real-time sequential deep extreme learning machine cybersecurity intrusion detection system," Comput. Mater. Contin., vol. 66, no. 2, pp.1785-1798, 2021.

[6] Yazan Otoum, Dandan Liu and Amiya Nayak, "DL-IDS: a deep learning-based intrusion detection framework for securing IoT," Trans. Emerg. Telecommun. Technol., vol. 33, no. 3, e3803, Mar 2022.

[7] Zeeshan Ahmand, Adnan Shahid Khan, Cheah Wai Shiang, Johari Abdullah and Farhan Ahmad, "Network intrusion detection system: a systematic study of machine learning and deep learning approaches," Trans. Emerg. Telecommun. Technol., vol. 32, no. 1, e4150, Jan 2021.

[8] Keping Yu, Liang Tan, Shahid Mumtzaz, Saba Al-Rubaye, Anwer Al-Dulaimi, Ali Kashif Bashir and Farrukh Aslam Khan, "Securing critical infrastructures: deep-learning-based threat detection in IIoT," in IEEE Communications Magazine, vol. 59, no. 10, pp. 76-82, Oct 2021.

[9] Nasrin Sultana, Naveen Chilamkurti, Wei Peng and Rabei Alhadad, "Survey on SDN based network intrusion detection system using machine learning approaches," Peer-to-Peer Netw. Appl. 12, pp. 493-501, Mar 2019