結合生成式人工智慧與領域專家之協同流程：以資安法規為例建立高品質 LLM 指令微調資料集

李睿軒[1] 徐國鈞[2]
國立臺北商業大學人工智慧與商業應用碩士班[1],國立臺北商業大學資訊管理系[2]
11365008@ntub.edu.tw[1],Totoro.hsu@ntub.edu.tw[2]

摘要

隨著大型語言模型（Large Language Models, LLMs）於專業領域中的應用日益廣泛，如何提升其於特定領域內的可信度與實用性，成為當前研究與實務的重要課題。為此，進行指令微調（instruction tuning）已成為關鍵技術之一，而高品質資料集的建立則為影響微調效果的一大核心挑戰。傳統方法倚賴領域專家手動撰寫資料，不僅耗費大量人力，亦難以持續擴展。本研究提出一套結合生成式人工智慧（Generative AI, GenAI）與領域專家審核機制與迴圈式自動再生成流程之協同方法，旨在有效且可追溯地建立高品質之指令微調資料集。本研究以資全法規為實證場域，首先透過提示詞工程（prompt engineering）導入相關法規條文，利用大語言模型生成候選的資料集；接續由多位資安領域專家針對正確性、完整性與可解釋性進行嚴謹審核。通過審核者納入最終資料集，未通過者則依據專家回饋再度驅動生成模型進行資料再產出，持續迭代直至品質達標。實驗中以多種參數規模之開源模型為基礎，評估其在本協同流程下之資料品質表現，並量化再生成機制所帶來之品質提升幅度。初步結果顯示，於 3 輪迴圈內，資料通過率由 49.6% 提升至 96.3% 驗證本方法於效率與品質兩個維度的優勢。綜上所述，本文所提出之流程具備可監管性與可追蹤性，能顯著提升專業領域 LLM 指令微調資料集之構建效率與品質，亦可作為其他高度規範領域（如醫療、法律、金融）開發私有化語言模型之實務參考範式。

關鍵詞：大型語言模型、指令微調、提示詞工程

Abstract

With the increasing adoption of Large Language Models (LLMs) in specialized domains, enhancing the reliability and domain alignment of LLMs has become a critical challenge. Instruction tuning is a key approach to achieving this goal, yet constructing high-quality instruction-tuning datasets that ensure both trustworthiness and traceability remains a major bottleneck. Relying solely on domain experts to create such datasets is costly and labor-intensive. To address this issue, this study proposes a collaborative framework that integrates generative AI, expert review, and iterative regeneration. We demonstrate the proposed approach in the context of cybersecurity regulatory texts. The system first employs prompt engineering techniques to guide the LLM in generating candidate instruction-response pairs based on relevant legal provisions. These candidates are then reviewed by multiple cybersecurity experts, who assess each sample for correctness, completeness, and actionability. Pairs that meet the evaluation criteria are accepted into the final dataset, while those that fail are regenerated using expert feedback as reference, in a looped process until the predefined quality standards are met. We conduct experiments using several open-source models with varying parameter sizes to evaluate their performance in generating regulatory instruction-tuning datasets. Furthermore, we quantify the effectiveness of the regeneration mechanism in improving data quality. Preliminary results show that, after N regeneration cycles, the approval rate increased from A% to B%, validating the efficiency and quality improvements enabled by our framework. In summary, the proposed human-AI collaborative process provides a transparent and traceable pathway to constructing high-quality instruction-tuning datasets for domain-specific LLMs. This methodology holds strong potential for deployment in other highly regulated sectors, such as healthcare, law, and finance.

Keywords: large language model、instruction-tune、prompt engineering

1. 緒論

1.1 研究背景

隨著生成式大型語言模型（Large Language Models, LLMs）在醫療、法律、金融及資安等高度專精領域的落地實證快速累積，學界與業界普遍發現，僅依賴大規模通用語料訓練之基礎模型，難以精準回應領域特有的術語與複雜推理情境。透過指令微調（instruction tuning） 進行二次訓練，已被證實能在多個專業基準上帶來 15－30 %的準確率提升。例如美國陸軍研究中心公開的 TRACLM 系列模型，經指令微調後，在軍事問答與行動計畫推理任務上的得分即較基線顯著成長[1]。

然而，高品質指令微調資料集的傳統產製流程高度依賴資深專家逐條撰寫，不僅耗時亦成本高昂。若任務複雜度上升或需高階專業領域人員參與，費用會更高，使得資料集產生更為困難。更高費用且時效緩慢的流程使資料往往在完成前已過時，使模型難以因應「新興威脅」或「新修法條」。

此外，在許多應用中，LLM 逐漸可以取代傳統以領域專家完成的文本相關工作，如 Gilardi 等人發現在文本注釋任務中，ChatGPT 在80%的任務中準確率超過人為標註，此為 ChatGPT 標註的成本為人為標註的5%[2]。在資安領域，IBM Research 所發表的 SecKnowledge 結合「LLM 生成

—專家調校—多輪驗證」的策略，訓練出的 CyberPal.AI 系列模型，在 SecKnowledge-Eval 基準上較基線平均提升高達 24% 成效[3]。這些證據顯示，生成式 AI 若能與人類知識適當結合，有潛力大量降低資料標註成本並提升資料品質。

1.2 研究動機

近近年全球資安事件急遽增加，2024 年帳戶外洩數據從前一年的 7.3 億筆暴增至逾 55 億筆，平均每秒即有 180 筆帳戶遭洩漏[4]。美國 Snowflake 雲端平台攻擊更波及多家大型企業，外洩個資與財務資訊，成為年度重大資安事故。與此同時，國際資安法規快速升級：歐盟《NIS2 指令》自 2024 年 10 月起要求涵蓋風險管理、事件通報與企業問責，違規可處以高達全球營收 2% 的罰款；美國 CIRCIA 法案則強制關鍵基礎設施於 72 小時內通報事件、24 小時內通報支付贖金。此顯示企業正面臨「即時通報」與「可稽核證據鏈」的嚴格監管，亟需可信任的輔助工具因應快速變動的合規挑戰。

在此背景下，大型語言模型（LLMs）因其自然語言理解與推理能力，被視為協助企業解讀法規與提供落地建議的潛在技術。然而，若缺乏具備可追溯性與審核機制的專領域資料，模型生成的建議極易出現錯誤，不僅可能造成罰款與信譽受損，甚至成為新的資安風險。當前學術界對資安法規文本的研究仍缺乏一套系統化、可驗證的方法論，尤其在條文映射、版本控管與審核留痕等面向存在不足，而國際 AI 治理趨勢也已明確要求高風險模型具備問責性與可追溯性。

台灣產業經驗進一步凸顯此一缺口。金融業如凱基人壽在培訓中嘗試導入生成式 AI，但因模型精準度不足，只能依靠多重提示工程與人工審核；OneDegree 的資安長則指出，缺乏資料更新與稽核機制會使法遵部門傾向否決專案；公共服務領域則出現臺北捷運智慧客服因防護不足而生成程式碼的爭議，引發安全質疑。製造業與中小企業則因語境與術語不被模型正確辨識，導致實際應用困難。這些案例顯示企業挑戰不僅來自技術瓶頸，更涉及合規、資安、組織落地與語境適配等多重問題。

因此，目前對「可信任資安 LLM」的需求日益增加。本研究提出結合生成式 AI 的高速資料生成能力與專家審核控制，建構具備即時更新、可追溯與問責性的資料生產流程，不僅回應產業合規落地的痛點，也呼應可信任 AI 在透明性與治理上的長期目標，構成本研究的核心學術驅動力。

1.3 研究目的

本研究旨在設計並驗證一套結合生成式 AI、專家審核與迴圈再生成的人機協作流程，以應對資安領域資料建構的高成本、時效落後與合規風險。流程設計上，系統先透過提示詞工程（prompt engineering）引導大型語言模型生成初始指令-回應樣本，再由資安法規專家依語意正確性、完整性與可操作性進行審核，並針對未通過樣本提供回饋以引導再生成，確保品質與審核痕跡。

研究將以資安法規文本為實證場域，比較純自動生成與人機協作流程下資料集品質的差異，並量化迴圈再生成對通過率的提升效果。同時，本研究將測試多種參數規模的指令微調模型，驗證不同資料來源與再生成策略對模型處理法規任務的影響。

此外，本研究亦評估該流程於醫療、法律、金融等高度規範場域的適用性，期望建構一個具追溯性、可驗證與可重複應用的資料生產架構，為可信任資安 LLM 的落地提供制度化管道，並推動跨領域可信 AI 方法論之發展。

2. 文獻探討

2.1 指令微調與資料集建構技術

在大型語言模型（LLMs）領域中，「指令微調」已成為提升模型理解與執行人類指令能力的關鍵技術。Zhang 等人（2023）在其綜述中指出，指令微調透過人工撰寫的指令-回應對資料集，以監督方式重新訓練模型，使語言模型得以彌合與人類自然語言互動目標之間的鴻溝[5]。

進一步而言，2024 年 Zhang 等人的論文進一步探討資料選擇策略，指出在指令微調的上下文中，資料品質遠比資料數量更重要。其將資料評估與選擇方法分為品質導向、分佈多樣性與重要性導向等類別，並強調合理選擇高品質子集能提高訓練效率與效果[6]。

然而，不同的指令資料來源與生成方式往往帶來成本與品質之間的權衡。Chen 等人（2023）在題為「Maybe Only 0.5 % Data is Needed」的研究中探討低資料量下的指令微調表現，發現只使用原始資料的0.5%樣本即可達到與全量資料相似的效能，甚至提升約 2%（Low Training Data Instruction Tuning）[7]。這類實驗結果揭示，若能妥善選取高資訊密度樣本，即可有效降低計算與標註成本。

關於標註成本與人機協作方面，Artemova 等人（2025）於 COLING 教程中提出生成式 AI 與專家審核流程（hybrid labeling / active learning）可顯著加速標註並降低成本，同時維持數據品質。而 Appen 的實地案例也表明，透過多 prompt 組合與熵值衡量策略，可將標註準確率維持在 87%，並削減最高 62% 的成本與三倍時間[8]。

綜合上述研究，可見目前領域已具備幾大核心洞見：第一，建立高品質指令-回應資料集是提升 LLM 執行準確度的必要條件；第二，資料選擇與資料量優化（如低資料量指令微調）可削減成

本，提升生成效率；第三，人機協作流程（human-in-the-loop）作為輔助生成與篩選機制，能在品質與速度之間取得平衡，特別適用於高風險與高度專業領域場景。

但上述文獻也顯現出幾項侷限：目前多數研究聚焦在通用或法律、醫療等語料相對成熟領域，尚缺乏針對資安法規領域的專屬方法。本研究將透過引入版本控管、專家回饋機制與迴圈再生成設計，補足上述方法上的不足，並提升資安法規文本資料集構建之品質與合規性。

2.2 人機協作與生成式 AI 的應用

隨著大型語言模型（LLMs）在自然語言處理任務中表現日益精進，研究社群開始探討如何將其作為資料標註的輔助工具，形成所謂「人機協作」或「human-in-the-loop」的資料建構模式。傳統的人工標註流程往往面臨高成本、低效率與一致性不穩等問題，而生成式 AI 透過提示詞（prompt）驅動，可快速合成大量候選樣本，成為取代或輔助人類初步產製標註資料的重要替代方案。

近年有研究提出將主動學習（active learning）與不確定性估計納入人機協作架構中，提升審核樣本的資訊密度。例如，Zhou et al.（2023）結合語意分散性與模型信心評分，僅需挑選資訊豐富子集進行人工複核，便可達成與全量審核近似的資料品質，進一步降低人力需求[9]。

儘管人機協作策略已有顯著技術發展，然而目前應用案例多集中於醫療影像標記、知識問答或語義配對等資料相對穩定的場域，對於如資安法規這類具備高時效性、敏感性與多版本疊代的文本任務，仍缺乏細緻探討。尤其在法規語境下，資料樣本的有效性往往不僅取決於語意是否合理，更牽涉是否引用正確條文版本、是否具備合規可操作性、以及是否留下審核與修改紀錄，這些皆為當前主流生成標註流程所未涵蓋之層面。

因此，本研究所提出之資料建構流程，嘗試進一步將生成式 AI 與專家審核的協同邏輯拓展至法規語義場域，並導入條文版本控管、審核痕跡標示與再生成品質量化等模組，使整體流程不僅能快速生成高品質訓練資料，亦符合未來 AI 治理規範中對於「可追溯性」與「責任歸屬」的要求。

2.3 法律與資安文本處理任務研究

在法律文本處理領域，研究者長期致力於開發專門模型以理解條文、案情與法理推理。Chalkidis 等人的 LEGAL-BERT 即透過法律語料的預訓練與微調，顯著優於通用 BERT [10]；近期如 SaulLM-7B 與 LawLLM 等模型，更展現出在條文理解與前例推理上超越 GPT-4 的潛力，顯示專屬語料與架構能有效提升表現 [11][12]。

在資安文本處理方面，研究亦逐漸聚焦於 LLM 解讀安全通報、威脅資料與政策條款。《LLM4Security》的系統性回顧整理逾 185 篇文獻，指出雖已廣泛使用提示詞工程、微調與資料增強，但仍受限於資料集不足、治理與隱私風險 [13]。此外，NVIDIA 提出的專屬資安模型，透過原始操作紀錄訓練，相較通用 LLM 更能識別與回應複雜威脅，展現專用模型於資安場景的可行性 [14]。

同時，也有研究將 LLM 應用於法律條文與合同分類、語彙抽取，並探討提示詞工程與微調如何提升模型對法律術語與條款映射的效率 [15]。這顯示在法律與資安場景中，模型必須兼顧語意準確性與結構理解。

然而，文獻仍存在幾項缺口：其一，資安法規文本的專屬指令微調資料集尚未有系統化設計，現有方法多集中於通用法律或安全任務，難以即時反映法規演進；其二，雖有專業語料訓練，但缺乏整合專家審核痕跡與版本標注的治理機制；其三，多數系統仍難確保資料與決策過程的可追溯性與合規性，未能符合國際 AI 治理對高風險模型的要求。

本研究即針對上述缺口，結合法規文本專屬演算法、專家審核與迴圈再生成策略，持續反映條文更新並保留審核與版本資訊，以打造符合資安法規特性且具追溯性與合規性的指令微調資料生成流程。

3. 研究方法

3.1 系統架構與工作流程

本研究設計一套完整且可追溯的人機協作流程，融合生成式 AI、領域專家審核與迴圈再生成機制，以支撐高品質、合規且高效率之資安法規指令微調資料建構。整體流程涵蓋七大階段：資料採集與提示詞設計、候選樣本生成、專家審核、回饋整合與 prompt 更新、迴圈再生成、品質評估與最終導入。

在提示詞設計與候選生成階段，基於法律條文與資安規範語境，設計 prompt 樣板以驅動 LLM 生成初步指令-回應對。生成模型使用如表2所示，包含多個系列與不同參數量的開源大語言模型，以確保輸出語料既多樣又符合專業語境，同時評估不同模型生成之效果。

其中，選擇參數量的方式基於生成效果同時希望能在一般消費型顯示卡中運行，所以選定在10億至100億之間。

接下來在專家審核階段，多位資安法規領域專家共同評估候選樣本的語意正確、內容完整與可操作性。審核結果可選擇通過與不通過，若選擇不通過，則可針對該樣本給出調整方向，例如條文補充、格式重構或措辭修正。

在專家審核階段，本研究邀請的審核者皆具備資訊安全與法規遵循相關的專業資格與豐富實

表 1 資料集樣本範例

指令	公務機關應如何制定資通安全維護計畫？
輸入	我們要建立一個資通安全策略，這樣做法則是什麼？
輸出	你的資通安全策略應包括以下事項：核心業務及其重要性、資通安全政策與目標、推動組織、專責人力與經費配置、公務機關資通安全長配置、資通系統及資產盤點與標示、風險評估、防護及控制措施、通報、應變及演練機制、情報評估與因應機制、委外服務管理措施、考核機制和精進與績效管理機制。
歷史對話	"什麼是資通安全管理法？", "資通安全管理法是保護國家電子資訊系統的法律，規定公共和私人部門應取得資通安全認證、建立資通安全維護計畫等措施。"

務經驗。參與的專家群體涵蓋曾於中央部會擔任資安稽核委員的資深顧問、現職於大專院校資訊中心的技術專員，以及具教育部資安稽核與檢測中心經驗的技術人員。他們不僅熟悉資訊安全管理制度與個資保護規範，亦持有多項國際資安與個資保護相關稽核證照，並長期參與教育體系與公共機構的資安檢測與輔導工作。這樣的專家組成確保了本研究審核流程的專業性與客觀性，使生成樣本在正確性、完整性與合規性上均能獲得嚴謹驗證，並符合國際 AI 治理要求所強調的「專家介入」與「審核留痕」原則。

若樣本未符合門檻，則進入回饋整合與 prompt 更新階段。系統將專家回饋整合樣本資料，將其中失誤類型、缺漏資訊與表述建議整合為 prompt 調整條件，例如「法源引用錯誤」、「回答不完整」等。prompt 更新後，進行下一輪生成。

表 2 使用之大語言模型

大語言模型系列	參數量
deepseek-r1	1.5b
	14b
	7b
	8b
gemma3	1b
	4b
	12b
gemma3n	e2b
	e4b
llama3.1	8b
llama3.2	1b
	3b
mistral	7b
qwen2.5	1.5b
	3b
	7b
	14b
qwen3	1.7b
	4b
	8b
	14b

該流程採用迴圈再生成（iterative regeneration）機制，直至資料通過率達預設標準（如≥80%通過率），每輪生成皆與前輪做品質比較，以衡量生成與審核策略在資料品質上逐步優化的效益。

於整體流程中，亦建立品質評估與最終導入機制：系統自動統計通過率、模型預測與審核意見一致性，以及 QA 任務實測結果與專家評分對照分析，確保資料集具備訓練價值。

流程設計也強調治理與可追溯性要求：每筆生成樣本都附 metadata，包括所引用法規版本、prompt 版本號、專家審核紀錄、修改日誌與樣本當前狀態，完整記錄在資料 pipeline 中供 audit 與日後查驗使用。此設計符合 OECD AI 原則與 AI Act 關於可追溯性與可解釋性的規範要求。

整體而言，此系統架構具有多階段生成—審核—優化機制，強調生成速度與專家控制並重，確保資料品質同時具備可重複實驗性與治理合規性。整體流程架構如圖1所示。

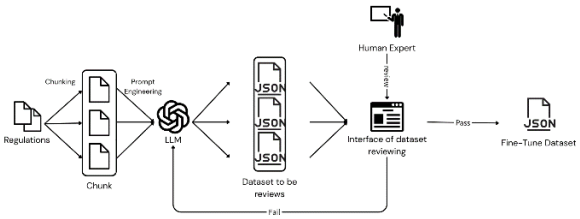

圖 1 本研究之系統架構

3.2 提示詞工程與迴圈再生成策略

本研究中，提示詞工程是構建高品質指令回應資料生成流程的核心。為提升生成樣本的準確性與一致性，採用以下策略：

首先，在提示詞設計方面，融合「Prompt Chaining」與鏈式思考（Chain-of-Thought, CoT）技術，將複雜的法規任務分解為多階段子任務以逐步引導模型生成。Sun 等人的研究顯示，Prompt Chaining 可以提升模型對長文本任務的掌握度，並提高可控性與解釋性（例如在研究摘要任務中表現優於單一 prompt）[16]。同時，CoT 提示法可啟發模型生成中間推理步驟，提升複雜條文推理任務中的準確性與穩定性（如「步驟式思考」提示

能顯著增強模型性能）。

其次，本研究採用迴圈式提示優化（Iterative Prompt Refinement） 機制，透過專家回饋與品質評估結果進行 prompt 持續調整。將 prompt 調整轉化為科學流程，不斷透過微調語句、增補上下文或修改格式以優化生成效果。

在生成參數調控與模型選擇方面，依照產生任務的複雜度與通用性要求，選用不同規模的開源模型，包括但不限於 LLaMA3.2、Qwen3、DeepSeek-R1。為保持 prompt 設計的一致性與可追溯性，每一 prompt 模板均進行版本管理與 metadata 標注，方便後續追踪調整歷程並支持生成流程審核。

整合上述設計，本研究的提示詞工程體系兼具結構性與靈活性。通過多輪 prompt 調整、Prompt Chaining 細化階段結構，以及 CoT 技術提高推理穩定性，此過程旨在引導模型生成具有法規解釋、合規操作建議及可操作性高的指令樣本，為後續專家審核與指令微調訓練提供穩健資料基礎。

3.3 系統實作與操作流程

為了實現上述流程，本研究開發一套網頁式 AI 資安資料集審核系統，整合生成與審核功能以支援人機協作。系統主要模組包括：法規條文管理、候選資料生成、待審核資料集管理、資料審核介面、最終資料集管理與模型統計儀表板。以下透過介面說明其功能與操作流程：

法規條文管理：管理者可將資安法規條文上傳或匯入，並維護版本資訊。系統會將文本按條款分段儲存，作為生成模型的知識來源。介面顯示已匯入法規清單與條文數量，方便後續選取。

候選資料生成：管理者可選擇法規來源並點擊「從法規生成」，系統會依提示詞模板逐條向 LLM 發出請求，批量產生候選指令－回應對。生成時可指定模型，並支援多模型並行以比較產出。

待審核資料集管理：生成樣本會進入「待審核資料集」。每筆資料包含模型輸出、指令內容、法規依據、模型名稱及對話歷史，並標示審核狀態（通過/拒絕）。專家可檢視細節並手動重新生成。

資料審核介面：同時顯示指令、回答及法規依據，供專家對照檢驗。下方提供「通過」與「拒絕」按鈕：通過樣本累計至閾值後自動加入最終資料集；拒絕則需輸入修改意見，並回饋至 Prompt 更新模組。

最終資料集管理：審核通過的樣本會自動加入最終資料集。管理者可檢視、管理並匯出高品質資料，用於模型微調。

模型統計：系統提供模型層級統計，包括樣本總數、通過數、拒絕數與通過率，方便比較不同模型的表現。

3.4 評估指標

為了衡量本研究生成式 AI 與專家協作流程的成效，我們主要採用兩項核心指標：通過率（Approval Rate） 與迴圈提升幅度（Iterative Improvement）。

(1) 通過率（Approval Rate）：通過率用以衡量候選樣本在專家審核下被接受的比例，其公式可形式化定義如下：

$$AR^{(r)} = \frac{1}{N_r \times M} \sum_{i=1}^{N_r} \sum_{j=1}^{M} 1(e_{i,j}^{(r)} = 1)$$

其中$AR^{(r)}$表示在第r輪迭代下的平均通過率；N_r為第r輪所生成並送交審核的樣本總數；M為參與審核的專家人數；$e_{i,j}^{(r)} \in \{0,1\}$代表專家所給予的審核結果（1 表示通過，0 表示不通過）：$1(\cdot)$為指示函數。此定義確保通過率同時考量 樣本數量 與 多位專家的一致評估，能更全面反映資料集的品質。

(2) 迴圈提升幅度（Iterative Improvement）：迴圈提升幅度衡量人機協作流程中，隨著多輪再生成與專家回饋修正，資料品質提升的幅度。其定義如下：

$$\Delta AR^{(r)} = AR^{(r)} - AR^{(r-1)}, r \geq 2$$

其中$\Delta AR^{(r)}$代表通過率提升幅度。透過此指標，可以直觀比較不同模型在多輪審核中的收斂效果，並量化專家回饋對品質優化的實質貢獻。

本研究透過通過率與迴圈提升幅度兩項指標，能有效量化人機協作流程中資料品質的變化，並作為第四章實驗設計與分析的基礎。

4. 實驗結果

為了評估本研究所提人機協作流程的有效性，本研究設計一系列實驗來比較純模型自動生成與專家協同流程下資料集品質的差異，並量化迴圈再生成機制對品質提升的影響。同時分析不同參數規模模型在此流程中的表現差異，以探討模型能力與資料品質的關係。

法規資料與模型設定： 本研究選取臺灣現行的九部資安相關法規（如表2所示），共包含約 200 條條文，作為知識來源輸入系統。所有法規文本均已透過系統的法規管理模組匯入並逐條儲存。並使用表1中所列的大型語言模型進行資料生成比較。這些模型涵蓋參數規模的跨度，有助於觀察模型大小對初始生成品質的影響。每種模型各自隨機對一筆至多筆條文生成至少30筆候選指令－回答對，共計產生 246 筆候選樣本。雖然九部法規

條文總計約 200 條，但由於模型生成過程中，部分條文會衍生出多個候選問答對，而部分條文則可能未能產生可用輸出，因此最終獲得 246 筆候選樣本。此數量在初步驗證階段屬於合理範圍，既能覆蓋多數法規條文的代表性，又能確保專家審核負擔在可接受的規模內，兼顧效率與品質的平衡。生成過程中使用相同的提示詞模板以確保比較公平。

表 3 使用之資安相關法規

法規名稱	條目數量（筆）
個人資料保護法	57
個人資料保護法施行細則	33
資通安全管理法	23
資通安全責任等級分級辦法	22
資通安全事件通報及應變辦法	21
資通安全管理法施行細則	13
資通安全情資分享辦法	11
特定非公務機關資通安全維護計畫實施情形稽核辦法	10
公務機關所屬人員資通安全事項獎懲辦法	7

在初始生成階段，所有模型產出的候選樣本經過人工篩除亂碼後，直接進入專家審核流程。第一輪審核結果顯示，不同參數規模的表現差異明顯，小型模型（2B－4B）能夠達到 43.8% 至 71% 的接受率，顯示其在法規場景下具有一定的穩定性。然而，隨著參數規模增加至 7B 以上，初始表現並未呈現線性提升，反而在 12B 與 14B 的模型上出現接受率偏低的情形，部分甚至低於 40%。整體而言，第一輪的平均接受率僅 40%，顯示單次生成難以保證高品質輸出。

在導入專家回饋並更新提示詞後，第二輪迭代展現出顯著改善。整體平均接受率由第一輪的 49.6%（246 筆中 122 筆通過）大幅提升至 88.3%（103 筆中 91 筆通過），顯示迴圈再生成能有效修正初始錯誤。大型模型改善最明顯，如 deepseek-r1 由 37.1%（35 筆中 13 筆）提升至 100%（11 筆全數通過），gemma3 亦由 38.5% 提升至 100%。中型模型 qwen2.5 與 qwen3 分別由 57.4% 升至 88.9%、由 60.0% 升至 83.3%；小型模型 gemma3n（2B－4B）則從五成提升至 88.9%，顯示修正對不同規模模型皆具助益。

第三輪進一步呈現收斂，整體平均接受率達 96.3%（54 筆中 52 筆），幾近完全一致。此時多數模型已達最終穩定，如 deepseek-r1、gemma3、gemma3n 與 mistral 全數 100%，qwen2.5 與 qwen3 亦分別維持 94.7% 與 95.0%。若從參數規模觀察，7B 與 8B 模型第三輪均達 100%，而 14B 模型雖首輪僅 57.8%，最終仍升至 93.5%，顯示大型模型經多輪修正後能逐步趨近高品質輸出。

綜觀三輪，模型品質並非單純依賴參數數量。第一輪差異明顯，小型模型甚至僅 0% 至 20%；第二輪引入專家修正後整體已近九成，第三輪更達九成半以上，幾乎所有模型均趨於一致。這說明最終品質的關鍵不在於參數規模，而在人機協同的再生成與專家回饋機制，透過多輪修正可將輸出引導至高一致性與可靠度。

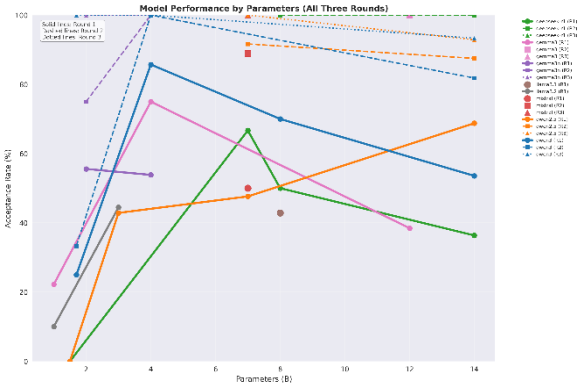

圖 5 三輪次模型接受率比較

從模型系列角度來看，不同架構差異明顯。gemma3n 在小規模參數下即可維持五成以上通過率，後續更提升至近乎滿分，展現良好可修正性。qwen3 與 qwen2.5 則屬「中段起步、高效收斂」，第一輪約六成，但第二、三輪均達九成以上，最終表現接近大型模型。deepseek-r1 進步幅度最大，第一輪僅 37.1%，第二輪與第三輪皆達 100%。相對地，mistral 與 llama3.1 維持在五至六成之間，顯示其調整空間有限。整體而言，不同系列模型在專業法規語料下的起始表現、修正能力與最終品質各具特色，並非僅由參數規模決定。

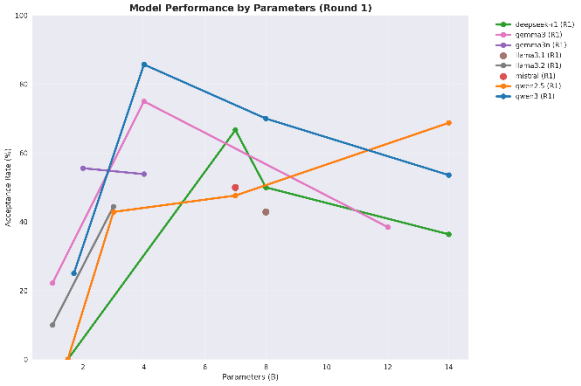

圖 6 模型系列通過率比較

從參數規模角度來看，結果呈現非線性。最小的 1.0B 與 1.5B 模型第一輪僅 15.8% 與 0%，難以生成可用輸出；2.0B 與 4.0B 接受率則達 64.3% 與 82.3%，後續表現尤佳，成為效率與品質的平衡點。7.0B 與 8.0B 模型初始約五至六成，第三輪均達 100%，展現高度潛力；12.0B 初始僅 52.9%，最

終仍提升至滿分；14.0B 初始 57.8%，最終達 93.5%。整體來看，參數數量與接受率並非正比，大模型在第三輪展現穩定性，但 4B 與 7B－8B 反而在效率與收斂速度上表現最佳。

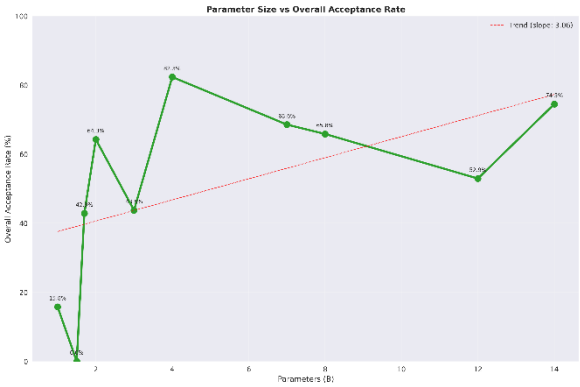

圖 7 模型參數量通過率比較

綜合而言，本研究的數據顯示，在資安法規文本的指令微調資料建構過程中，迴圈再生成機制是決定資料品質的關鍵因素。第一輪的平均接受率僅為 49.6%，部分小型模型甚至低於兩成，凸顯了單純依賴模型本身輸出難以達到高品質。然而，在第二輪引入專家回饋後，平均接受率已經提升至 88.3%，並在第三輪達到 96.3%，大部分模型突破九成甚至達到滿分。這意味著，資料品質的提升並不僅依賴模型大小或系列架構，而是仰賴「人機協作＋多輪再生成」的設計。最終成果不僅驗證了該流程能兼顧效率與品質，也提供了可延伸至其他高風險領域（如醫療、法律、金融）的重要實證基礎。

5. 結論與未來展望

本研究成功驗證了一套結合生成式人工智慧與領域專家之協同流程，用於高品質 LLM 指令微調資料集的構建。本研究以資安法規場域驗證該流程的有效性：透過提示詞工程引導模型自動生成候選資料，並由專家嚴格審核與提供反饋，配合迴圈式再生成，大幅提升資料樣本的通過率和整體品質。同時，本研究將資料生產過程的關鍵資訊全部記錄，確保資料集的可追溯性，符合高風險 AI 系統的治理要求。在模型層面，發現初始生成的平均通過率僅約四成，但在導入迭代機制後，整體接受率可提升至七成半以上；小型模型在第一輪就展現穩定表現，中大型模型則在專家回饋下進步幅度最大，最終表現趨於一致。相較傳統完全人工標註，此方法大幅降低人力成本、縮短製作週期，並能隨著法規更新持續迭代，解決資料時效落後的難題。這些成果對推動可信任資安 LLM 的發展具有重要的實務價值。

未來將可從幾個方向深化與擴展本研究：首先，在跨領域應用方面，可將此流程應用到醫療指南、金融法規等其他領域，驗證其通用性並根據不同領域需求調整流程細節，如擴充專家回饋類別和提示詞模板庫。其次，在自動化程度方面，可引入主動學習策略，讓系統自動判斷哪些候選樣本最有資訊價值，優先送交專家審核，以進一步減輕人工作業量。此外，也考慮整合強化學習（如以專家反饋作為獎勵的強化學習微調）來替代部分 prompt 手動調整，使模型能更自主地改善迴圈中的表現。另一方面，也會將生成的資料集實際用於微調大語言模型，並研究此研究生成的資料集所微調出來的大語言模型與預訓練之大語言模型的回答差異。

總而言之，結合生成式 AI 與專家智慧的人機協同流程為高品質領域資料集建構提供一種高效、可靠且可監管的解決方案。隨著 LLM 技術與各國 AI 監管的持續發展，此類強調可追溯、高品質的資料生產範式將扮演愈發重要的角色。我們期望本研究的成果能為後續的研究與實務提供有益參考，推動更多領域建立自己的指令微調資料集，加速專業領域專用 LLM 的創新與落地。

參考文獻

[1] Ruiz, Daniel C., and John Sell. "Fine-Tuning and Evaluating Open-Source Large Language Models for the Army Domain." arXiv preprint arXiv:2410.20297 (2024).

[2] Gilardi, Fabrizio, Meysam Alizadeh, and Maël Kubli. "ChatGPT outperforms crowd workers for text-annotation tasks." Proceedings of the National Academy of Sciences 120.30 (2023): e2305016120.

[3] Levi, Matan, et al. "Cyberpal. ai: Empowering llms with expert-driven cybersecurity instructions." Proceedings of the AAAI Conference on Artificial Intelligence. Vol. 39. No. 23. 2025.

[4] Surfshark B.V. . Global Data Breach Statistics: A 2024 Recap. 14 Apr. 2025. Surfshark, Accessed 12 Aug. 2025.

[5] Zhang, Shilong, et al. "Gpt4roi: Instruction tuning large language model on region-of-interest." European conference on computer vision. Cham: Springer Nature Switzerland, 2024.

[6] Zhang, Bolin, et al. "A survey on data selection for llm instruction tuning." arXiv preprint arXiv:2402.05123 (2024).

[7] Chen, Hao, et al. "Maybe only 0.5% data is needed: A preliminary exploration of low training data instruction tuning." arXiv preprint arXiv:2305.09246 (2023).

[8] Artemova, Ekaterina, et al. "Hands-on tutorial: Labeling with llm and human-in-the-loop." arXiv preprint arXiv:2411.04637 (2024).

[9] Zhou, Jeffrey, et al. "Instruction-following evaluation for large language models." arXiv preprint arXiv:2311.07911 (2023).

[10] Chalkidis, Ilias, et al. "LEGAL-BERT: The muppets straight out of law school." arXiv preprint arXiv:2010.02559 (2020).

[11] Colombo, Pierre, et al. "Saullm-7b: A pioneering large language model for law." arXiv preprint arXiv:2403.03883 (2024).

[12] Shu, Dong, et al. "LawLLM: Law large language model for the US legal system." Proceedings of the 33rd ACM International Conference on information and knowledge management. 2024.

[13] Xu, HanXiang, et al. "Large language models for cyber security: A systematic literature review." arXiv preprint arXiv:2405.04760 (2024).

[14] Gorkem Batmaz. Building Cyber Language Models to Unlock New Cybersecurity Capabilities. 9 Jul. 2024. NVIDIA Developer Blog. Accessed 12 Aug. 2025.

[15] Breton, Julien, et al. "Leveraging LLMs for legal terms extraction with limited annotated data." Artificial Intelligence and Law (2025): 1-27.

[16] Sun, Shichao, et al. "Prompt chaining or stepwise prompt? refinement in text summarization." arXiv preprint arXiv:2406.00507 (2024).

[17] Desthuilliers, A. (2024, November 14). *How a Human-in-the-Loop Approach Enhances AI Data Quality*. Appen Blog.

[18] European Commission. (2021). Proposal for a Regulation laying down harmonised rules on Artificial Intelligence (Artificial Intelligence Act). COM(2021) 206 final.

[19] Google Cloud. (2025). Prompt iteration strategies. (Vertex AI Generative AI Documentation, updated July 31, 2025).

[20] OECD. (2019). Recommendation of the Council on Artificial Intelligence. OECD Legal Instruments OECD/LEGAL/0449.