國立臺北商業大學管理學院
資訊管理系人工智慧與商業應用碩士班
碩士學位論文

檢索增強生成與微調大語言模型於資安管理應用之研究

Application of Retrieval-Augmented Generation and Fine-Tuned LLMs in Cybersecurity Management

研究生：李睿軒

指導教授：徐國鈞 博士

中華民國一一五年一月

國立臺北商業大學管理學院
資訊管理系人工智慧與商業應用碩士班
碩士學位考試委員會審定書

資訊管理系人工智慧與商業應用碩士班研究生 李睿軒 君

所提論文 檢索增強生成與微調大語言模型於買家管理應用之研究

合於碩士資格水準，業經本委員會評議認可。

學位考試委員會

召集人 陳偉銘

委員 李文敏

徐國勳

陳偉銘

指導教授 徐國勳

系主任 葉明貴

中華民國 115 年 1 月 9 日

國立臺北商業大學 National Taipei University of Business 1912 NTUB

摘要

隨著資訊安全威脅型態日益多樣化，管理標準與合規要求亦逐漸嚴謹。然而，多數非資訊安全專業背景的使用者在實務上常面臨理解門檻高、規範複雜及風險評估困難等挑戰，導致其在資訊安全管理與合規實踐上存在顯著落差。基於此，本研究提出一套結合檢索增強生成技術（Retrieval-Augmented Generation, RAG）與大型語言模型（Large Language Models, LLMs）指令微調之人工智慧代理系統，期望協助非專業使用者在資訊安全管理情境下提升任務執行能力與合規表現。

本研究之系統架構涵蓋兩項核心設計。首先，建構以資安法規知識庫所組成的 RAG 架構，透過將組織內部資安政策與管理文件動態整合至結構化知識檢索框架，使語言模型能產出更具針對性與合規性之回應。其次，依據現行台灣資訊安全相關法規，並結合專家審核，編製專屬指令微調資料集，以強化語言模型對資安術語、合規邏輯及風險判斷之理解與應用能力。

本研究之主要貢獻在於提出一套結合 RAG 與 LLM 微調之人工智慧代理架構，能有效整合組織內部知識與語言模型之語意處理能力，並提升系統回應之準確性與一致性。透過此架構，可有效降低語言模型產生幻覺（hallucination）之風險，並為非專業使用者提供具可靠性之資安管理輔助工具。此外，本研究成果亦可作為人工智慧導入組織性資訊治理與資安合規實務應用之參考，具備理論價值與實務貢獻。

Keywords: 檢索增強生成、微調大型語言模型、資訊安全管理、AI 代理系統

國立臺北商業大學 National Taipei University of Business 1917 NTUB

ABSTRACT

With the increasing diversity of cybersecurity threats, management standards and compliance requirements have become more stringent. However, users without a professional background in cybersecurity often encounter significant challenges in practice, such as high barriers to understanding, complex regulations, and difficulties in risk assessment. These challenges result in a substantial gap in their ability to effectively manage cybersecurity and ensure compliance. To address this issue, this study proposes an intelligent agent system that integrates Retrieval-Augmented Generation (RAG) with instruction-tuned Large Language Models (LLMs), with the aim of enhancing the task performance and compliance capabilities of non-expert users in cybersecurity management scenarios.

The proposed system architecture encompasses two core components. First, a Modular RAG Process is designed to dynamically integrate organizational cybersecurity policies and internal management documents into a structured knowledge retrieval framework, thereby enabling the language model to generate more targeted and compliance-oriented responses. Second, a domain-specific instruction-tuning dataset is developed based on current Taiwanese cybersecurity regulations and validated through expert review, in order to strengthen the model's understanding and application of cybersecurity terminology, compliance logic, and risk assessment..

The primary contribution of this study lies in the development of an intelligent agent framework that combines RAG and LLM fine-tuning, effectively integrating organizational knowledge with advanced language processing capabilities. This framework is expected to improve the accuracy and consistency of system responses while reducing the risk of hallucinations in language models. Ultimately, it provides a reliable cybersecurity management support tool for non-expert users and offers a feasible application paradigm for introducing artificial intelligence into organizational information governance and compliance practices.

Keywords: Retrieval-Augmented Generation, fine-tuned Large Language Models, information security management, AI agent system

誌謝

時光荏苒，研究所兩年的學習與研究生活轉瞬即逝。回首這段歷程，從課程修習到研究發展，從主題確立到論文完成，每一個階段都凝聚著許多人的支持與協助。在此謹致上最誠摯的感謝。

首先，衷心感謝指導教授徐國鈞教授在研究期間的悉心指導與耐心啟發。從研究方向的確立、研究方法的建構，到論文架構與內容的反覆修正，教授皆給予專業且具前瞻性的建議。教授嚴謹的治學態度與對學術品質的堅持，使我在研究過程中學會以更高標準審視自己的成果，也培養了系統化思考與問題分析的能力。本論文得以順利完成，實仰賴徐教授的指導與鼓勵。

同時，特別感謝同學陳品茹在研究與論文撰寫過程中的協助與支持。無論是在研究討論、資料整理、技術交流，或是在遇到困難時的鼓勵與建議，都給予我極大的幫助。透過多次的交流與意見分享，使我在思考問題時能更全面，也讓研究過程更加順利。

此外，感謝口試委員撥冗審閱論文並提供寶貴意見，使本研究內容更加完善與嚴謹。也感謝研究室的同學與夥伴，在課業與研究交流中彼此切磋，使我在學術能力與實務經驗上皆有所成長。

最後，最深的感謝獻給我的家人。感謝父母長期以來對我求學與進修的支持與鼓勵，讓我能夠專心投入研究，無後顧之憂地完成學業。家人的理解與信任，是我持續前進的重要力量。

碩士階段的學習，不僅提升了專業能力，更培養了嚴謹思考與自我要求的態度。未來我將持續精進所學，將研究成果應用於實務與社會，期許自己在專業領域中持續成長。

謹以此誌謝，向所有支持與幫助我的師長、同儕與家人，致上最誠摯的謝意。

國立臺北商業大學 National Taipei University of Business 1917 NTUB

國立臺北商業大學 無違反學術倫理聲明書
National Taipei University of Business
Statement of Academic Ethics

立聲明書人 李睿軒 (學號：11365008）於資訊管理系人工智慧與商業應用研究所，撰寫檢索增強生成與微調大語言模型於資安管理應用之研究期間，業經指導教授指示：絕不可剽竊、抄襲及剪貼他人之論述，並已獲知剽竊、抄襲及剪貼論文之定義。因此，凡引述他人之觀點及圖表，本人皆在論文詳實註明出處，絕未涉及抄襲、剽竊及剪貼等違反學術倫理之情事。如有違反，本人除願意負起法律責任，並無條件同意由教育部及國立臺北商業大學註銷本人之碩士學位，絕無異議。

I declare that the texts, citations, charts, figures, illustrations, and pictures contained in the thesis titled Application of Retrieval-Augmented Generation and Fine-Tuned LLMs in Cybersecurity Management have no plagiarism of others' works nor violations of academic ethics. I accept legal liability for plagiarism and violations of academic ethics and completely agree the revocation of the Master's Degree granted to me by The Ministry of Education (Taiwan) and National Taipei University of Business if any of the said misconduct is confirmed true.

聲 明 人(Student)： 李睿軒 (親筆簽名 Signature)

中 華 民 國 115 年(Y) 02 月(M) 25 日(D)

*本聲明書之影本請裝訂於紙本內頁、掃瞄後電子檔加入電子論文內頁（目錄之前頁）。

目錄

摘要 I

ABSTRACT II

第一章 緒論 1

第一節 研究背景 1

第二節 研究動機 4

第三節 研究目的 6

第四節 研究架構 7

第二章 文獻探討 8

第一節 大型語言模型（LLMs） 8

第二節 檢索增強生成技術（RAG） 10

第三節 大型語言模型微調（FINE-TUNING）技術 14

第四節 文本切分技術（CHUNKING） 16

第三章 研究方法 19

第一節 系統架構設計 19

第二節 建構指令微調資料集 22

第三節 微調大語言模型 25

第四節 檢索增強生成 29

第四章 實驗結果 33

第一節 實驗資料集 33

第二節 實驗比較對象 35

第三節 評估指標 37

第四節 實驗結果 41

第五章 結論與未來展望 52

第一節 結論 52

第二節 未來展望 55

參考文獻 57

國立臺北商業大學 National Taipei University of Business 1917 NTUB

圖目錄

圖 1-1　2021~2024 年全球每週每個組織平均遭受網路攻擊次數統計 2
圖 2-1　PFM 的歷史與演進 8
圖 3-1　本研究之系統架構圖 19
圖 3-2　微調模型訓練損失折線圖 28
圖 4-1　微調模型與微調＋RAG 模型之跨模型指標差異熱圖 42
圖 4-2　微調模型與微調＋RAG 模型之整體平均提升統計 42
圖 4-3　預訓練模型與預訓練＋RAG 模型之跨模型指標差異熱圖 43
圖 4-4　預訓練模型與預訓練＋RAG 模型之整體平均提升統計 44
圖 4-5　預訓練模型與僅微調模型之跨模型指標差異熱圖 44
圖 4-6　預訓練模型與僅微調模型之整體平均提升統計 45
圖 4-7　預訓練模型與微調＋RAG 模型之跨模型指標差異熱圖 46
圖 4-8　預訓練模型與微調＋RAG 模型之整體平均提升統計 46
圖 4-9　預訓練＋RAG 模型與僅微調模型之跨模型指標差異熱圖 47
圖 4-10　預訓練＋RAG 模型與僅微調模型之整體平均提升統計 47
圖 4-11　LLM-as-a-Judge 評分結果 48
圖 4-12　LLM-as-a-Judge 評分差異比較 49

表目錄

表 3-1　使用之資安相關法規 23

表 3-2　資料集樣本範例 24

表 3-3　微調之開源大語言模型列表 27

國立臺北商業大學
National Taipei University of Business
1917
NTUB

第一章　緒論

第一節　研究背景

在當今高度數位化的社會中，各類組織如教育機構、中小企業、公部門與非營利組織正面臨日益加劇的資訊安全威脅。根據 Check Point Research 發布的《A Closer Look at Q3 2024: 75% Surge in Cyber Attacks Worldwide》報告（Check Point Research, 2024），自 2021 年以來，全球組織平均每週遭受的網路攻擊次數逐年上升。以 2024 年第三季為例，平均每週攻擊次數達 1,866 次，相較於 2023 年同期（約 1,064 次）成長超過 75%，顯示網路攻擊強度大幅升高（見圖 1-1）。這一趨勢不僅揭示了攻擊規模的急遽擴張，也反映攻擊手法的日益多樣化與複雜化，包括勒索軟體、社交工程、零日漏洞利用與資料外洩等，對組織的營運穩定性、財務安全及合規性構成嚴峻挑戰[1]。

為降低資安風險與法規違規風險，組織需導入具備彈性、可擴充且符合最新標準的資訊安全管理機制。然而，當前的資安管理框架與標準日益複雜，除要求技術能力外，亦須理解風險評估、存取控制、資料保護與應變程序等核心概念。對於非資安專業背景的一線人員而言，如學校行政人員、中小企業主與地方政府承辦人員，在實務操作中常因缺乏訓練而難以正確解讀技術性指引、評估潛在風險、或妥善執行資安管理任務。舉例而言，校務行政人員需設定學生資料系統的存取權限，小企業負責人需應對疑似釣魚郵件，地方政府單位則需定期回報資訊安全現況。上述任務若執行不當，將可能成為攻擊者入侵或橫向擴散的初始接口。

更進一步地，資安標準與政策（如 ISO 27001、NIST SP 800 系列等）為因應快速變化的攻擊樣態，經常進行版本更新與補充。非專業使用者若無法即時理解並實施最新要求，將可能落入合規盲點或產生實施落差。雖然市面上已有各類資安管理工具，這些工具多為專業人員設計，重點放在流程整合與控制自

動化，缺乏針對非專業人員設計的語意引導、案例說明與組織情境調適功能。因此，使用者在執行安全任務時容易出現設定錯誤、誤解規範或忽略漏洞等問題，進而削弱整體組織的資安防護力。

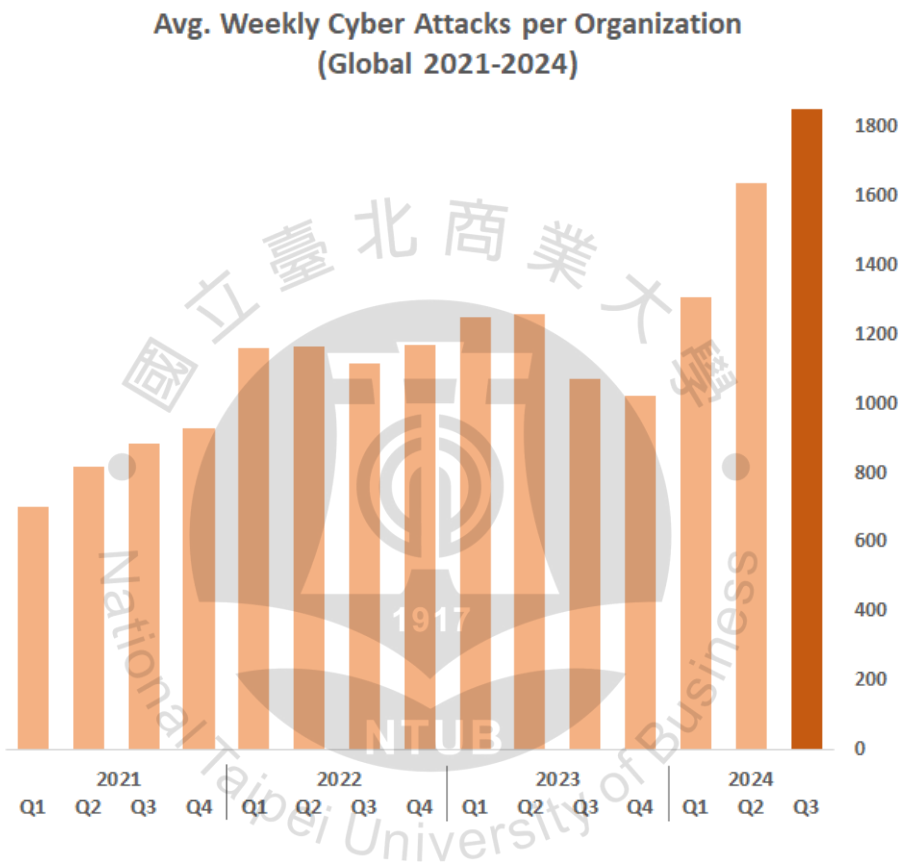

圖 1-1　2021~2024 年全球每週每個組織平均遭受網路攻擊次數統計

資料來源：Check Point Research（2024），A Closer Look at Q3 2024: 75% Surge in Cyber Attacks Worldwide

隨著生成式人工智慧（Generative AI）技術的快速發展，特別是大型語言模型（Large Language Models, LLMs）與檢索增強生成（Retrieval-Augmented Generation, RAG）技術的成熟，為資訊安全管理開啟了新契機。LLMs 擅長語意理解與自然語言生成，RAG 則能動態擷取外部知識以補強模型回應能力，兩

者已廣泛應用於教育輔助、醫療決策、法律解釋與客服自動化等領域。例如，在醫療領域中，結合 RAG 與臨床文獻可支援醫師快速取得診斷建議；在法律場景中，微調後的 LLM 可輔助法務人員釐清條文意義與適用條件。這些應用顯示出，AI 展現出在高知識密度與高度規範場域中，提供結構化與語境導向支援的潛能。

然而，這類技術於資訊安全領域的應用仍處於初步階段，特別是針對非專業使用者之任務支援系統設計與評估，仍缺乏完整且系統性的研究。為回應此一實務需求與研究空缺，本研究聚焦於人工智慧技術於資訊安全任務輔助之應用潛力，針對非專業使用者於資安管理任務執行中所面臨的知識障礙與操作落差，提出一套具可行性、可擴充性與高可用性的 AI 支援系統，期能降低錯誤風險、強化合規表現，並促進資訊安全治理的普及與智慧化。

國立臺北商業大學
1917
NTUB
National Taipei University of Business

第二節　研究動機

近年來，大型語言模型（LLMs）如 GPT 與 BERT 的技術突破，顯著推動自然語言處理（Natural Language Processing, NLP）領域的發展，使其廣泛應用於文本摘要、問答系統、機器翻譯與對話式人工智慧等多種場景。在資訊密集與語意複雜的任務中，LLM 展現出強大的語言生成與理解能力，成為當代人工智慧系統的核心組件之一。

然而，當通用語言模型應用於特定領域任務時，往往暴露出語義精確性不足與事實一致性不穩的問題。特別是在資訊安全合規領域，通用模型常因缺乏最新的法規知識而產生嚴重的「語言幻覺（hallucination）」。舉例而言，當企業詢問「依據 NIST 框架，密碼應多久更換一次？」時，通用 ChatGPT 可能依據過時資料建議「每 90 天更換一次」，然而最新的 NIST SP 800-63B 標準已不再建議強制定期更換密碼，除非發生入侵跡象。若非專業人員採信此錯誤建議，不僅徒增管理成本，更可能因使用者便宜行事（如僅微調密碼字尾）而降低整體安全性。 此類錯誤在資訊安全領域尤為敏感，若建議內容失真，將可能引發合規違失、資安漏洞，甚至造成組織層級的風險擴散。。研究指出，LLM 容易產生「語言幻覺（hallucination）」現象，即生成表面合理卻實質錯誤或誤導性的語句[2]。此類錯誤在資訊安全領域尤為敏感，若建議內容失真，將可能引發合規違失、資安漏洞，甚至造成組織層級的風險擴散。

為提升語言模型應用於特定任務中的可靠性，「檢索增強生成（RAG）」技術逐漸受到重視。RAG 結合語言模型與即時資訊檢索能力，能於生成回應前從外部知識來源（如內部政策庫、法規資料集、威脅情報平台）中擷取相關內容，進而提升生成內容的依據性與上下文精確度[3]。該機制特別適用於資訊快速變動、知識更新頻繁的領域，如網路資安、法律諮詢與醫療診斷。然而，RAG 的效能仍高度依賴於「檢索器」的精確性與文件結構設計，若文件標註不完整或

檢索結果過度冗長，模型仍可能在生成過程中發生語意錯解。

為補強大型語言模型在特定領域的適應性，「語言模型微調（fine-tuning）」技術提供另一重要路徑。透過針對特定領域語料（如資安政策、稽核報告、事件通報格式）進行指令微調（instruction fine-tuning），可有效內化領域術語、強化合規邏輯與提升用語風格的專業性。以資訊安全領域而言，模型透過微調後可更準確地對應 ISO/IEC 27001、NIST SP 800-30 等管理架構與控制標準，產生較具可信度的輔助性建議。然而，微調模型本質上仍為靜態學習結果，無法即時因應政策更新或威脅情報變化，導致在實務應用中存在時效性落差。

綜合而言，RAG 與微調技術具有高度互補性：前者強調知識即時性與回應依據性，後者則強化語言模型對特定語境與標準的熟悉度。兩者若能結合，將可建構出具備組織特定性與語意準確性的智慧型資訊安全建議系統，特別適用於規範導向與高可靠性需求之應用場景。

儘管如此，現有研究多集中於 LLM 微調技術於資安文本分類、威脅情境生成或自動化稽核報告輔助等應用，RAG 架構亦主要應用於法規查詢與技術文件摘要等場景。針對「非專業使用者」在資訊安全作業中所需的任務導引、規範解釋與情境化建議等需求，目前尚缺乏結合 RAG 與微調技術之整合型系統。現行資安工具大多設計給專業操作人員使用，其介面與邏輯架構預設使用者具備資安背景知識，忽略了一般使用者對於語意可理解性、政策可解釋性與任務可執行性的需求。

因此，本研究針對上述學術與應用斷層，提出一套結合 RAG 與微調技術之 AI 資安輔助架構，旨在協助非專業使用者於資訊安全任務中獲得即時、準確且符合組織內部規範的語意化指引，促進資安管理的普及性、可及性與智能化實踐。

第三節　研究目的

本研究旨在開發一套結合檢索增強生成技術（RAG）與微調大型語言模型（LLMs）之人工智慧代理系統，協助缺乏資安專業背景之使用者，在無需專業訓練的前提下，亦能正確、有效且符合法規要求地執行資訊安全相關任務。此系統期能補足現行資安管理工具對非專業使用者支援功能之不足，提供具備動態知識擷取與語境適應能力的個人化安全建議。

在具體目標上，本研究將首先建構一個可針對組織內部政策文件與國際資訊安全標準進行動態檢索與知識對應的 AI 輔助架構，透過 RAG 技術確保生成的回應內容具備明確依據並符合組織規範。其次，本研究將透過語言模型的領域微調，強化模型對資安術語、控制措施及新興威脅的理解能力，以提升生成建議的精確度與合規一致性。此外，研究將設計並驗證系統原型，透過實證實驗評估其在準確性、合規性與可用性三個面向的表現，從而檢驗該系統在實務應用中的有效性與可行性。

在可行性方面，本研究具備多重優勢。技術上，RAG 架構與語言模型微調已為成熟方法，且相關工具如向量資料庫與開源模型已廣泛可得，可降低系統實現的技術門檻；資料上，組織內部規範文件、稽核報告以及國際資安標準文本皆可作為檢索與微調語料，具備高度結構化與專業性，能有效支撐系統設計；應用上，現有資安工具大多預設使用者具備專業知識，對非專業人員的支援不足，因此本研究所提出的架構能回應實際需求，特別適用於教育機構、中小企業與政府單位等資源有限卻需高度合規的場域。

整體而言，本研究不僅將提出一套具體可行的 AI 資安輔助架構，藉由結合 RAG 的即時知識檢索能力與微調模型的領域適應性，提升系統在真實應用場景中的實用價值，更能為學術界與實務界提供一種新穎的整合模式，拓展生成式人工智慧於智慧化資訊治理與資安管理中的應用實例。

第四節　研究架構

本論文共分為五章，依循問題提出、技術基礎、系統設計、實證驗證至結論展望的研究脈絡進行鋪陳，完整呈現本研究自動機形成到系統實作與成效評估的過程，說明如下：

第 1 章為緒論，說明本研究之背景與問題意識，指出非專業使用者在資訊安全管理任務中所面臨的挑戰，並揭示現行資安管理工具在使用性與語意輔助層面的不足。進一步提出研究動機與研究目標，概述技術構想與預期應用價值，並對本論文之整體結構進行總覽。

第 2 章為相關研究，回顧本研究所依據的理論基礎與技術現況，涵蓋大型語言模型（LLMs）、檢索增強生成技術（RAG）、文件分割技術（chunking）與語言模型微調（fine-tuning）方法，並分析其在資訊安全、法律與醫療等高合規性與風險敏感領域的應用潛能。同時檢視現有資訊安全工具的功能定位與限制，進一步凸顯本研究之切入點與技術整合的必要性。

第 3 章為研究方法，詳細說明人工智慧資安代理系統的設計與實作流程。本章將呈現系統整體架構，包括 RAG 流程與組織知識整合機制、語言模型微調流程，以及各模組間的互動邏輯。特別強調系統如何回應非專業使用者的實際操作需求，並確保建議內容同時具備可理解性與合規性。

第 4 章為實驗設計與成效評估，針對系統進行實證檢驗。本章將說明所採用的資料集、評估指標與實驗結果，並分別比較預訓練模型、微調模型以及微調模型搭配 RAG 的回答效果，藉此驗證本研究架構之可行性與實用性。

第 5 章為結論與未來展望，統整本研究之成果與學術貢獻，並針對系統設計與應用提出後續可能的改進方向，例如語料庫規模之擴充、跨領域應用之延伸，以及針對大型組織落地導入條件的可行性探討，作為未來研究與實務推廣之參考依據。

第二章　文獻探討

第一節　大型語言模型（LLMs）

大型語言模型（LLMs）已成為自然語言處理（NLP）領域的核心技術，推動語言理解、文本生成與對話式人工智慧等應用取得顯著進展。GPT（Generative Pre-trained Transformer）與 BERT（Bidirectional Encoder Representations from Transformers）等模型即為其中代表，這些模型利用 Transformer 架構處理大量語料，學習詞彙、語句與段落間的語境關聯[4]，並在多項通用 NLP 任務中達到最先進的表現水準。

Zhou 等人（2024）所進行的綜合性回顧研究，系統性地追溯了從 BERT 到 ChatGPT 等預訓練基礎模型（Pre-trained Foundation Models, PFMs）的發展歷程，強調這類模型於文本、圖像與圖形等多模態任務上的應用潛力與延展性（見圖 2-1）。該研究指出，基礎模型的高度通用性與可擴展性使其成為處理語言理解複雜任務的重要工具[5]。然而，儘管具有高度靈活性，通用型 LLM 在應用於如醫學[6]與法律[7]等專業領域時，常因術語特化與任務精度需求而面臨顯著挑戰。

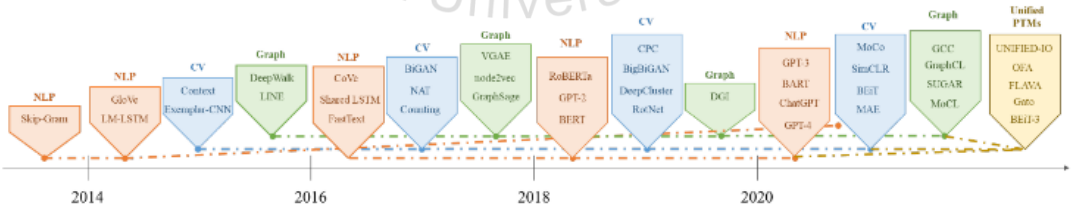

圖 2-1　PFM 的歷史與演進

資料來源：Zhou, C., Li, Q., Li, C., Yu, J., Liu, Y., Wang, G., … & Sun, L. (2024). A comprehensive survey on pretrained foundation models: A history from bert to chatgpt. International Journal of Machine Learning and Cybernetics, 1-65.

然而，即便 LLM 模型能力日益上升，其在專業領域應用中仍存在數項系統性限制，最受關注的侷限之一即為通用型 LLM 的「語言幻覺（hallucination）」問題，即模型可能生成語意合理但事實錯誤或具誤導性的內容。此一問題已由 Ji 等人（2023）與 Huang 等人（2023）深入探討，並被認為在資訊安全等高風險領域中尤其關鍵，因為錯誤回應可能導致嚴重後果。因應此一問題，亟需透過增強模型事實準確性與領域專屬性的機制來加以補強[2][8]。

現有文獻多強調 LLM 的廣泛應用潛力，但對其在專業領域落地時的「可控性」與「可信度」討論仍顯不足。現有研究提出的解法大致分為兩類：一是透過更大規模與更多樣化的語料進行訓練，以期減少幻覺現象[9]，但此方法成本高昂，且無法保證在快速演變的專業領域中即時有效；二是透過結合外部知識來源或限制生成範圍來增強模型的事實性[10][11]，但這類方法在檢索準確性與知識整合效率上仍面臨挑戰。

綜合而言，LLM 已展現革新 NLP 應用的潛力，但若要應用於資訊安全等高風險專業情境，僅依靠其通用能力仍不足以確保結果的準確性與合規性。現有研究雖提出若干增強策略，但在如何平衡生成能力、事實準確度與領域專屬性方面仍缺乏成熟解法。因此，本研究將聚焦於檢視「檢索增強生成（RAG）」技術與模型微調如何補足 LLM 在專業應用中的不足，以提升其在資訊安全領域的適用性與精確性。

第二節　檢索增強生成技術（RAG）

隨著大型語言模型（Large Language Models, LLMs）在自然語言生成與理解任務中的表現日益卓越，其於各種知識密集型應用中的潛力亦逐漸受到關注。然而，由於這類模型主要依賴於預訓練階段中所學得的靜態知識，其參數中所儲存的資訊往往無法即時反映外部世界的變化（如新法規、技術更新與安全威脅趨勢）。在知識變動頻繁的領域，例如資訊安全、醫學、法律與金融，這一限制特別明顯[8]。此外，大型語言模型的「語言幻覺」（hallucination）問題亦構成重大挑戰，模型可能在缺乏足夠事實依據時生成看似合理但實際錯誤的回應[2]。因此，如何在保留 LLM 語言理解能力的同時，引入外部可驗證的知識來源，成為提升其事實一致性（factual consistency）與專業可靠性的重要研究方向。

Retrieval-Augmented Generation（RAG）架構由 Patrick Lewis、Ethan Perez、Aleksandra Piktus 等人於 2020 年提出。該研究針對「知識密集型自然語言處理任務」（Knowledge-Intensive NLP Tasks）提出一個整合檢索（retrieval）與生成（generation）的雙模組架構，旨在提升模型於需要外部知識支援的任務（如問答、事實驗證、實體消歧等）中的效能與可解釋性[3]。

RAG 的核心思想是將語言模型的生成過程與外部文件庫相結合。當模型接收到查詢（query）後，首先由檢索模組（retriever）根據語意相似度從知識庫中選取若干相關段落；接著，生成模組（generator）會將這些檢索結果與原始查詢一併作為輸入，以生成最終回應。檢索模組通常使用密集向量檢索器[3]，而生成模組則搭配大型語言模型生成依照檢索內容的回答內容。這種「檢索增強」（retrieval-augmented）的方式，使得語言模型不再僅依賴於參數內部儲存的靜態知識，而能在生成過程中動態引入外部資訊。

Lewis 等人（2020）的實驗顯示，RAG 在多項開放領域問答任務（如 Natural Questions、TriviaQA、WebQuestions）上皆顯著優於傳統生成模型（如 BART）

與僅使用檢索的模型（如 DPR）。其中，RAG-Sequence 模式（將檢索片段逐一輸入生成模型）與 RAG-Token 模式（在 token 層面融合檢索結果）均展示了穩定的性能提升。研究者進一步指出，RAG 架構具有可模組化特性：檢索器與生成器可獨立替換與訓練，使其能根據任務需求調整知識來源與生成策略。此設計理念為後續一系列 RAG 改良模型奠定了理論基礎[3]。

在 RAG 架構提出後，研究社群針對其可擴展性與事實一致性進行了多項改良與擴充。Guu et al. (2020) 於 REALM: Retrieval-Augmented Language Model Pre-Training 中，提出在預訓練階段即結合檢索機制，使模型能學習何時及如何利用外部文件進行推理，從而實現「端到端檢索學習」（end-to-end retrieval learning）。REALM 的創新在於將檢索過程融入語言模型訓練流程中，而非事後附加，顯示檢索與生成間可進行共同優化[12]。

隨後，Izacard & Grave (2021) 提出的 Fusion-in-Decoder (FiD) 模型則針對 RAG 的生成效率進行改良。FiD 採用多文件輸入機制，將檢索到的多篇文件同時送入解碼器進行上下文融合，提升了多來源資訊整合的能力。此方法在 Open-Domain QA 任務上取得了顯著進步，並被廣泛應用於後續 RAG 研究[13]。進一步地，Borgeaud et al. (2022) 在 Improving Language Models by Retrieving from Trillions of Tokens 一文中提出 Retro 架構，利用外部資料庫檢索相似上下文片段（neighbors）來輔助 Transformer 模型生成，實驗證明該方法能在不增加參數量的情況下顯著提升模型效能[14]。

近期，Izacard et al. (2023) 的 Atlas 系統將 RAG 應用於大規模語言模型的知識持續學習，結合檢索與指令微調（instruction tuning）策略，使模型能持續吸收新知識而不產生遺忘效應（catastrophic forgetting）[15]。此外，Edge et al. (2024) 提出的 Graph RAG 則將文件間的語義關聯以圖結構方式建模，使模型在檢索階段能同時考量概念節點與上下文邏輯連結，特別適用於具層級依賴與因果關係的專業領域，如法規、醫療與資訊安全[9]。其延伸版本 LightRAG（Guo

et al., 2024）進一步簡化圖譜構建與索引流程，減少運算資源需求，適合計算資源有限的環境部署[10]。

綜上，RAG 架構的演進顯示出一個明確的研究趨勢：從早期單純的文件檢索輔助生成，逐步發展為多模態、圖結構化、甚至知識持續更新的智慧生成系統。這些技術路徑共同指向一個目標——提升語言模型在知識密集任務中的即時性、事實一致性與推理能力。

RAG 架構的最大貢獻在於為大型語言模型提供了一種「外部知識即插即用」（plug-and-play knowledge integration）的能力。透過結合檢索器與生成器，模型可根據查詢動態存取最新或領域專屬的知識，從而克服 LLM 訓練語料靜態化與時效性不足的問題。這對於政策法規、醫療研究、學術文獻及資訊安全等需高度準確與即時性的任務尤其關鍵。

在資訊安全領域中，RAG 能夠整合來自國際標準（如 ISO/IEC 27001、NIST CSF、GDPR）與本地法規（如《資通安全管理法》）的文件內容，根據用戶查詢檢索相關條文與控制措施，並生成具有情境化建議的回答。例如，當使用者詢問企業在特定威脅情境下應採取之控制策略時，RAG 系統可即時檢索最新政策與最佳實踐文件，生成兼具合規性與專業邏輯的建議。此特性不僅提升了生成結果的可解釋性與信任度，亦為建構「法遵導向 AI 輔助系統」提供了可行架構。

儘管 RAG 在多項知識密集任務中展現優異性能，但近年文獻亦指出其在實際應用中仍存在若干限制，主要包括以下幾個面向：

檢索與生成間的語意落差（Retrieval-Generation Mismatch）：Shuster et al. (2021) 指出，RAG 的生成器常無法充分利用檢索器提供的內容，導致生成文本未完全反映外部知識，甚至忽略關鍵資訊。該現象源於檢索階段與生成階段的目標不一致：前者追求語意相似度最大化，而後者注重語境可讀性與語法流暢，兩者間的語義橋接問題（semantic alignment gap）限制了模型整體性能[16]。

事實一致性與幻覺問題仍未根除：雖然 RAG 藉由外部知識減輕了幻覺（hallucination）問題，生成模型在文本組合過程中仍可能融合不一致或矛盾的資訊，導致「混合幻覺」(hybrid hallucination)。當檢索結果存在歧異或模糊語境時，模型難以判斷事實真偽，仍需人類審查或輔助判定。

效能與延遲問題（Latency and Efficiency）：RAG 系統在實際部署中常面臨檢索延遲與運算資源消耗問題。大規模向量檢索與生成模型推理同時進行時，系統延遲與記憶體需求會顯著上升，限制其於即時應用（real-time applications）中的可行性。雖然後續如 LightRAG 等架構嘗試透過索引壓縮與稀疏圖檢索改善效率，但在資源受限環境中仍具挑戰[10]。

領域適應性不足（Domain Adaptation）：RAG 的檢索器多以通用語料（如 Wikipedia）預訓練，對於特定領域（例如資訊安全、醫療、教育科技）之專有詞彙與上下文關係理解不足。因此，即使能檢索到相關文件，生成器亦可能無法充分解析其專業語義，導致回應內容過於概略或不符專業邏輯。

綜上所述，RAG 架構雖顯著提升了語言模型的事實一致性與知識可更新性，但其在語義對齊、知識品質、效能開銷及領域專化方面仍有待改進。這些限制顯示僅依賴檢索機制仍難以滿足高專業與高可靠性任務的需求。因此，近年研究趨勢逐漸轉向結合 RAG 與指令式微調（Instruction Fine-Tuning） 的混合策略，以強化模型對領域知識的深層理解與任務語境適應性。

本研究正是基於此觀點，於後續章節中將進一步探討如何透過微調技術，彌補 RAG 在專業任務中之知識解析與語境推理侷限。

第三節　大型語言模型微調（Fine-Tuning）技術

隨著大型語言模型（Large Language Models, LLMs）在自然語言處理領域中的快速擴展，其在通用語言理解、摘要生成、推論等任務上取得卓越成果。然而，若將此類模型直接應用於高度專業化的領域，如資訊安全、法規遵循、資安事件通報判準等情境時，往往因語料分布偏移（distributional shift）及缺乏領域背景知識，而導致生成內容在專業性、精確性與語境一致性方面不足。儘管檢索增強生成（Retrieval-Augmented Generation, RAG）能透過外部知識庫補充模型的事實性資料，其語義理解與邏輯判準仍需透過微調技術進行補強[17]。

微調（Fine-Tuning）旨在於大模型的通用預訓練基礎上，利用少量且具代表性的領域標註資料重新調整模型部分權重，使其更貼合領域專有語言型態、邏輯結構與推理規範。在資訊安全相關場景中，例如「資安事件通報」、「資通安全責任等級」、「個資外洩通報流程」等術語具有明確、不可混淆的法律含義，若未經微調，模型容易產生語義錯配或誤解制度意圖。故微調技術已成為使 LLM 能真正落地於法規與資安情境的核心環節[18]。

由於大型語言模型參數量已達數十億甚至千億級，傳統全參數微調需消耗大量 GPU 記憶體與運算資源，使其在實務部署上成本極高，也不利於多版本、多客戶環境的快速更新。因此，近年研究者提出一系列參數效率導向微調（Parameter-Efficient Fine-Tuning, PEFT）方法，使模型只需更新極少比例的參數即可達到與全參數微調相近的效能[19]。

低秩適配（Low-Rank Adaptation, LoRA）為最具代表性的 PEFT 方法之一。其核心概念是將模型權重矩陣的更新以低秩矩陣分解的方式進行，並在訓練過程中凍結原始權重，僅更新低秩參數。研究顯示，LoRA 只需不到 1% 的額外參數，即能在多種大型模型（如 GPT、RoBERTa、DeBERTa）上達到或超越全參數微調的效果，同時大幅降低訓練與儲存成本[20]。

QLoRA（Quantized LoRA）進一步將模型使用 4-bit 量化技術並搭配 paged optimizer，使得在單張 48GB GPU 上即可完成 65B 參數模型的微調。此技術保有 LoRA 的參數效率，同時透過量化壓縮大幅降低顯存消耗，在數個基準測試中表現接近 ChatGPT 等商用模型水準[21]。

PEFT 技術的成熟，使研究者與企業能以低成本快速生成多版本、客製化的專業領域模型，對資安、法規等需頻繁更新的知識體系更具有實際價值。

在微調前加入領域預訓練（Domain-Adaptive Pre-Training, DAPT）亦為提升模型專業能力的重要策略。透過大量未標註的專業語料——例如資安事件通報紀錄、法規釋義文件、威脅情資報告或稽核成果紀錄——可使模型建立穩固的領域語言基礎，進而提升後續監督式微調的收斂速度與生成品質。

領域預訓練與微調在大型語言模型應用中形成互補關係：

- DAPT：提升術語理解能力、法規語境掌握度
- 微調：補強任務特定推理能力、生成邏輯一致性
- RAG：確保模型回應具備最新、最完整的外部知識來源

若僅依賴 RAG 而未進行微調，模型雖可取得正確法規文本，卻可能因語義理解不足而做出錯誤詮釋；而微調後的模型能正確解讀條文意涵，並提供符合法規精神與業務邏輯的建議，對資訊安全法規輔助系統而言尤為關鍵[18]。

綜上所述，微調技術已成為將大型語言模型成功應用於資訊安全、法規遵循等高度專業領域的重要基礎。以 LoRA 與 QLoRA 為代表的參數效率導向微調，大幅降低了訓練成本，使模型能在資源有限的環境下維持高效能。結合 DAPT 與 RAG 的混合式架構，更能同時兼具語義理解、任務推理與知識完整性，形成當前最具實務價值的專業領域模型開發途徑。本研究即將基於此技術框架，建構一套專注於資訊安全法規的高可靠大型語言模型，作為專業資訊安全決策與合規輔助的核心引擎。

國立臺北商業大學 National Taipei University of Business NTUB

第四節　文本切分技術（Chunking）

在檢索增強生成（Retrieval-Augmented Generation，RAG）系統架構中，文本切分是長篇文件處理的核心前置步驟。因大型語言模型（LLMs）基於 Transformer 架構存在輸入長度限制，未經切分的長文本會導致關鍵語境截斷，降低檢索效率與生成準確性。有效的文本切分策略可以將長文拆分成語境連貫、語意完整且具檢索友好的小區塊，提升下游模型的資訊擷取品質與回答一致性[22][23]。

目前學術界已提出多種切分技術，以回應不同文檔類型與應用場景之需求：

首先，固定長度切分（Fixed-size Chunking） 係依照預設字元數或詞元數將文本均勻分割，具高度運算效率與實作簡便性，適用於結構高度規律之技術手冊或標準格式文件。然而，此法易打斷語意單元，造成語境割裂，在語義分布不均的文本中表現較差[22]。資安法規（如 ISO 27001 或資通安全管理法）通常具有嚴謹的條列結構。固定長度切分極易將「主條文」與其後的「款、目」切斷。例如，將「應辦理下列事項：」與具體事項切開，導致檢索時模型只看到後半段的動作，卻不知道這是針對哪個法規要求的，造成合規判斷錯誤。而在法規遵循任務中，完整性比長度一致性更重要，所以固定長度切分方式並不適用於資安管理的場景。

語義導向切分（Semantic Chunking） 則基於語義邊界進行文本區塊劃分，通常利用自然語言處理技術，如句法分析和語義角色標注，確保每塊涵蓋一個主題或語意單元。此方法能顯著提升檢索命中率和語意匹配度，對於政策文件或法律文本尤為重要[23]。雖然語意切分比固定長度好，但通用的 NLP 模型（如 BERT 或未微調的 Embedding 模型）可能無法識別資安法規特有的層級關係。

進一步發展的遞迴式切分（Recursive Chunking） 採多層次處理機制，先按段落、章節等大結構進行初步切分，再依據語句或邏輯指標（如項目符號）細分

為次級區塊。此一策略可保留文件的層次關係與語境脈絡，特別適用於政策文件、法律條文與資安規範等高度結構化之內容[24]。雖然遞迴切分能保留章節結構，但資安法規常有「跨條文引用」的情況。單純的遞迴切分無法處理這種邏輯跳躍，檢索時容易遺漏引用來源，導致解釋不完整。

此外，語境感知切分（Context-Aware Chunking） 進一步將文件的原生結構元素（如標題、標號、表格、程式碼區塊）納入切分考量，提升語意完整性與邏輯順序之保留度[25]。

近期技術發展則聚焦於自適應切分（Adaptive Chunking），即透過機器學習或語意分類演算法，依據文件內容之語義密度與查詢相關性動態調整區塊大小與邊界。該策略相較於靜態分段方法更具彈性，能提升語境涵蓋與檢索精度，特別適用於資訊異質性高且格式不一之資料庫，如威脅通報、稽核紀錄與多版本政策文件[22][23]。

文本切分不僅是 RAG 檢索階段的基礎，更直接影響語言模型的理解和生成能力。良好的切分策略能有效降低語言模型出現幻覺（hallucination）的風險，提升生成回答的準確度和可靠性。反之，切分不當可能導致語義斷裂，造成上下文誤解或資訊遺漏，尤其在資訊安全與法規遵循等需嚴格精確性的領域風險更大[23]。

現代 RAG 系統逐步注重文本切分與檢索索引的深度結合，例如以語意強連結的句群作為最小存取單位，兼顧檢索效率與語境完整性；同時結合多跳推理機制提升對複雜查詢的邏輯對應能力[23][24]。

綜上所述，現有的文本切分技術大多針對一般敘事性文本設計，旨在提升閱讀流暢度或問答覆蓋率。然而，應用於資訊安全管理與法規遵循場景時，面臨了結構破碎化（破壞法條完整性）、邏輯斷裂（遺失跨條文引用）以及專業語境缺失（無法區分強制性與建議性規範）等挑戰。因此，本研究認為必須發展一套結合法規結構特性的切分策略，以確保 RAG 系統在檢索時能獲取具備完整

法效性的知識單元。

國立臺北商業大學
1917
NTUB
National Taipei University of Business

第三章　研究方法

第一節　系統架構設計

本研究所提出之人工智慧代理系統，其整體系統架構如圖 3-1 所示，整合使用者查詢處理、文件語意切分與嵌入、向量資料庫建構、語意檢索、語境提示語生成與語言模型回應模組等關鍵組件。系統以語意驅動為核心設計理念，建構出一套具延展性、可維護性與任務導向性的智慧型資安輔助平台。透過語意檢索與語言生成的協同運作，該系統可針對使用者查詢提供即時且具合規邏輯之安全建議，特別適用於教育機構、公部門與中小企業等缺乏專責資安人力之場域。

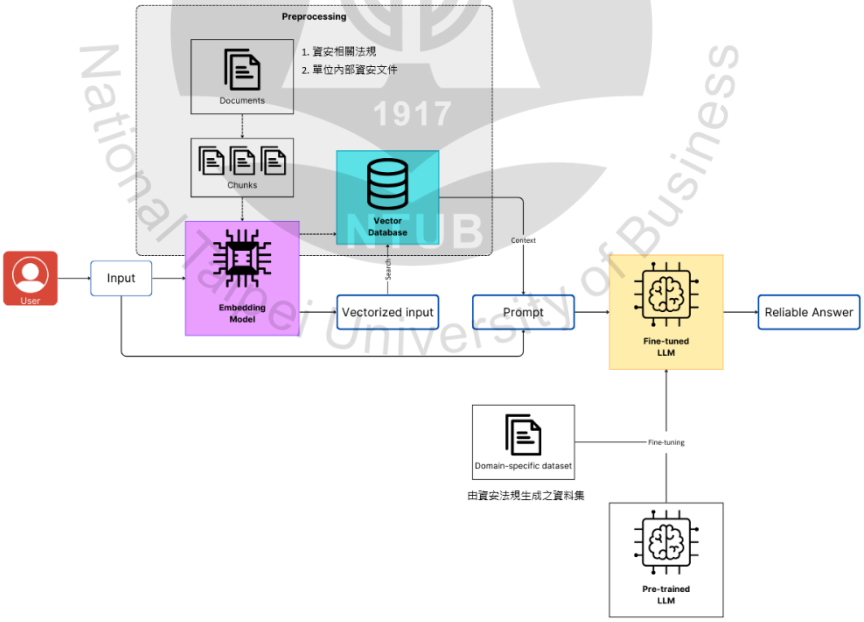

圖 3-1　本研究之系統架構圖

資料來源：本研究者繪製

整體系統流程以使用者自然語言輸入作為起點，查詢內容經過嵌入模型轉換為具語境辨識能力的向量表示，並送入語意檢索模組，在預先建構之向量資料庫中執行語意相似度比對，擷取最相關之文件段落。系統將所檢索之語境資訊與原始查詢整合為語境提示語（contextualized prompt），進一步傳送至本地部署、經微調之大型語言模型進行回應生成。最終，系統將生成結果直接回傳予使用者，提供其於資訊安全任務決策中可據以執行之建議或解釋。

系統資料庫中所儲存之內容可分為兩大類型。第一類為由各使用單位定期上傳與更新之組織內部文件，包括資安政策、內控作業流程、稽核規則與歷史事件通報等，屬動態維護資料；第二類則為由系統預先匯入之外部開放性權威資安知識，包括 ISO/IEC 27001、NIST Cybersecurity Framework、GDPR 條文與 CIS 控管項目等。系統設計亦支援外部知識之自動化更新，以確保所引用內容始終符合最新法規要求與產業趨勢。

為強化語意檢索精度與語境連貫性，所有文件於進入資料庫前須先經過前處理模組執行語義切分（semantic chunking）。該模組透過大型語言模型之語意識別能力，將長篇文檔分割為語意完整之段落片段（chunks），使向量資料庫得以精準對應查詢語境並提升後續回應生成之品質。切分後之段落再經嵌入模型轉換為語意向量，構成向量資料庫的核心索引單元。

查詢流程中，系統接收到使用者輸入後，會先將其轉換為向量表示並執行檢索。檢索模組將擷取語意最接近之段落內容，並與查詢整合為具情境特定性的語境提示語。該提示語將傳送至微調語言模型進行推論。系統所使用之模型為中型開源模型，具備運算效能與參數規模之平衡特性，並部署於本地伺服器，避免機敏資料經由外部網路傳輸，有效兼顧資安需求與成本可控性。

模型接收到提示語後，將結合查詢與語境進行語言生成，輸出具有語意邏輯與合規依據之自然語言回應。因系統架構採用語境強化提示與微調語言模型結合設計，生成回應不僅自然流暢，亦能回應組織內部規範與查詢任務邏輯。

完成生成後，系統將結果直接回傳予使用者，無需額外後處理，即可支援實際決策與作業指引。

此外，系統亦支援動態索引更新功能。當組織新增或修訂內部文件時，前處理模組會自動重新執行語義切分與嵌入程序，並更新向量索引，以確保所擷取與生成之內容基於最新資料版本，提升系統知識鮮活度與適應性。

透過上述架構設計與模組整合，本系統能夠有效將非專業使用者與複雜資安知識連結，提供精確、任務導向且可操作之資安建議，進一步實現資訊安全治理的普及化。

國立臺北商業大學
1917
NTUB
National Taipei University of Business

第二節　建構指令微調資料集

為使為使本研究所採用之大型語言模型（Large Language Models, LLMs）能夠生成具備任務語境、實務邏輯與法規依據的資訊安全建議，研究中導入了指令微調（Instruction Tuning）策略。而指令微調需要相應的微調資料集供大語言模型進行訓練，但目前市面上缺乏以臺灣在地資安法規為主體的微調資料集，所以本研究結合生成式人工智慧（Generative AI）與領域專家審核的協同流程，構建一套以臺灣在地法規為核心的高品質指令－回應資料集。此資料集旨在強化模型於查詢解析與回應生成階段之法規理解、合規判斷與實務應用能力，最終使模型具備多場域適應性與可追溯的法遵基礎。

本研究所使用的文本來源涵蓋臺灣資通安全相關法律，包含《資通安全管理法》、《個人資料保護法》與《資通安全責任等級分級辦法》等在地規範（詳見表 3-1）。透過納入完整的臺灣資安相關法規，資料集能理解台灣資安法規之執行細節，同時提升模型對查詢語境的理解與法規詮釋的精準度。

在資料集構建的第一階段，針對上述法規條文進行系統化文本處理。過程中移除格式雜訊、頁碼標註、註腳與非語意元素，並依照條目切分為不同的片段文本。每一片段皆保持法源出處與條次編碼，以確保後續生成過程能追溯至具體依據。

此階段的處理不僅確立語料的結構一致性，更為後續的任務生成提供了可控且可索引的語意單元，使模型能在生成階段具備上下文理解與語法一致性。

在資料轉換為結構化語料後，本研究使用提示詞工程設計提示詞用於產生基於單一或多筆法規的問答集。

在資料生成階段，本研究採用多種開源大型語言模型（如 Qwen3、DeepSeek-R1、Gemma3、LLaMA 3.2 等）作為生成引擎，並以優化後的提示語進行語料生成。每筆資料以五欄位之 JSON 結構儲存（如表 3-2）。

其中 source 欄位詳細標註資料出處（如條文編號、法規名稱、頁碼或官方文件連結），確保日後能追溯生成依據。

表 3-1　使用之資安相關法規

法規名稱	條目數量（筆）
個人資料保護法	57
個人資料保護法施行細則	33
資通安全管理法	23
資通安全責任等級分級辦法	22
資通安全事件通報及應變辦法	21
資通安全管理法施行細則	13
資通安全情資分享辦法	11
特定非公務機關資通安全維護計畫實施情形稽核辦法	10
公務機關所屬人員資通安全事項獎懲辦法	7

資料來源：研究者整理

為確保一致性與語法正確性，整個生成流程採用多輪模板優化機制與語法正規化控制，避免模型出現結構錯位或語意錯誤。

本階段研究的核心特色在於導入人機協作（Human-in-the-Loop）與迴圈再生成（Iterative Regeneration）機制。由具備資訊安全與法規遵循專業背景的多位審核專家，依據正確性、完整性與可操作性對生成樣本進行逐條審核。審核者可對未通過樣本提供具體修正建議，如「法源引用錯誤」、「語義模糊」、「缺乏應

變流程」等，系統再依建議自動更新提示詞並重新生成。此反饋－再生成流程持續進行，直至資料通過率達預設品質門檻。

表 3-2　資料集樣本範例

指令	公務機關應如何制定資通安全維護計畫？
輸入	我們要建立一個資通安全策略，這樣做法則是什麼？
輸出	你的資通安全策略應包括以下事項：核心業務及其重要性、資通安全政策與目標、推動組織、專責人力與經費配置、公務機關資通安全長配置、資通系統及資產盤點與標示、風險評估、防護及控制措施、通報、應變及演練機制、情報評估與因應機制、委外服務管理措施、考核機制和精進與績效管理機制。
歷史對話	"什麼是資通安全管理法？", "資通安全管理法是保護國家電子資訊系統的法律，規定公共和私人部門應取得資通安全認證、建立資通安全維護計畫等措施。"
來源	資通安全管理法

資料來源：研究者整理

最終生成之資料集涵蓋資訊安全治理、法規釋義、風險管理與制度建議等核心任務場景，形成一套具備語義深度、法規依據與合規脈絡的高品質訓練語料。該資料集可直接應用於大型語言模型微調階段，使模型在生成階段能精準引用法源、提供具操作性的建議，達成「專業可信任的 AI 資安顧問」目標。

第三節　微調大語言模型

為建構具備資安法規與合規知識的大型語言模型（Large Language Models, LLMs），本研究進行一系列微調（Fine-tuning）實驗。微調旨在使通用語言模型能更貼近特定領域的語境與任務需求，進而生成具備正確法規依據與專業邏輯的回答。本節將說明微調資料集擴充策略、模型選擇與實作架構、LoRA 技術原理與設定方式，以及後續之模型比較與評估方法。

由於原始高品質資料集係以嚴謹的法規內容與人機協作流程構建，其資料量雖具代表性但仍有限，難以支撐多模型、多輪次之系統性微調。因此，本研究採用「半自動合成資料生成」策略，結合既有的指令－回應資料與法規文本，利用大型語言模型生成補充性合成樣本，以增強資料集的多樣性與覆蓋度。

具體而言，首先以臺灣資通安全相關法規為核心語料，設計多層次指令模板（Instruction Templates），涵蓋合規要求解析、風險管理建議、事件應變程序、資安控制實作等類別。接著使用 GPT4o 模型依據模板生成多樣化的問答樣本。

最終形成的合成資料集與原始人工撰寫資料集合併後，經格式統一與樣本隨機化處理，構成最終微調資料集。此資料集內容涵蓋政策詮釋、法條說明、實務應用情境、技術實作建議與風險評估等多層面，能充分支持模型於多任務指令下進行語意理解與合規推理。

本研究採用 LLaMA Factory 框架進行模型微調[25]。該框架支援主流開源模型（如 LLaMA、Qwen、Mistral、Gemma 等），並整合 Hugging Face Transformers 與 PEFT（Parameter-Efficient Fine-Tuning）技術，具備高擴充性與可重現性。LLaMA Factory 亦支援多節點訓練、混合精度（FP16/BF16）與分布式梯度同步機制，有助於在有限 GPU 資源下完成大規模微調任務。

考量研究資源限制與模型可攜性，本研究採用 LoRA（Low-Rank Adaptation）技術進行參數高效微調。LoRA 的核心概念為在原始權重矩陣上加入低秩分解

矩陣。於訓練過程中，僅更新兩個低秩矩陣的參數，而原始權重保持凍結，從而大幅降低訓練參數數量與記憶體需求。此技術不僅能維持原始模型的語言生成能力，亦能在少量資料下有效學習新知識。

本研究針對多個開源基礎模型（如表 3-3）進行實驗，以評估不同模型架構在資安領域任務上的表現差異。所有微調實驗皆採用一致的訓練配置，以確保結果具備可比性。本研究的微調設定如下：

首先，本研究採用 LoRA 作為主要的參數高效率微調方法，並未使用額外的量化技術，模型以 BF16 精度進行訓練。LoRA 主要設定包括：rank = 8、α = 16、dropout = 0，以維持穩定的訓練過程。模型不啟用語言模型凍結功能，但會凍結 vision tower 與 multi-modal projector 等非文字模組，以避免產生不必要的運算成本。

在資料部分，所有實驗均使用本研究建立之資安域資料集，並將 20% 的資料用於驗證。文本最大長度設為 2048 token，以支援法規條文與長段落文本。模型不採用資料 packing 方式，確保逐筆資料的上下文完整性。

為兼顧效能與硬體限制，本研究採用 batch size = 2，並搭配 gradient_accumulation_steps = 8 以提升有效 batch size。在優化器方面，採用 AdamW，學習率設定為 5×10^{-5}，並使用 cosine learning rate scheduler。訓練週期設定為 3 epoch，warmup_steps = 0。梯度裁剪（max_grad_norm）設為 1.0，以避免梯度爆炸。每 100 step 保存一次 checkpoint（save_steps = 100）。訓練過程每 5 step 記錄一次 log（logging_steps = 5）。

此外，本研究啟用模型內建的思考模式，以支援具推理結構的訓練樣本，提高模型解釋能力與推理一致性。訓練階段設定為傳統監督式微調（Supervised Fine-Tuning, SFT），未啟用 PPO、DPO 或其他偏好式訓練（preference learning）策略，以確保模型主要學習資安領域事實規範與回答格式。

綜合以上設定，本研究在統一化的微調配置下，比較不同基礎模型於資安

法規理解、威脅情境分析與合規建議生成等任務之表現，以驗證模型架構差異對領域化微調效果的影響。

表 3-3　微調之開源大語言模型列表

模型系列	模型名稱	模型參數量（十億）
DeepSeek-R1	DeepSeek-R1-1.5B-Distill	1.5
	DeepSeek-R1-7B-Distill	7
	DeepSeek-R1-8B-Distill	8
Gemma	Gemma-2B	2
	Gemma-7B	7
Llama3	Llama-3-8B	8
Qwen2.5	Qwen2.5-1.5B	1.5
	Qwen2.5-3B	3
	Qwen2.5-7B	7
Qwen3	Qwen3-1.7B-Base	1.7
	Qwen3-4B-Base	4
	Qwen3-8B-Base	8

資料來源：研究者整理

所有實驗均在單張 NVIDIA RTX 4080 Super GPU 上進行，並透過梯度檢查點（Gradient Checkpointing）技術進一步降低顯示記憶體消耗。

每次訓練均以相同資料集進行，確保模型間比較具公平性。訓練完成後，模型權重以 Hugging Face 格式保存，便於後續部署與推論。訓練過程之損失函數變化如圖 3-2 所示。

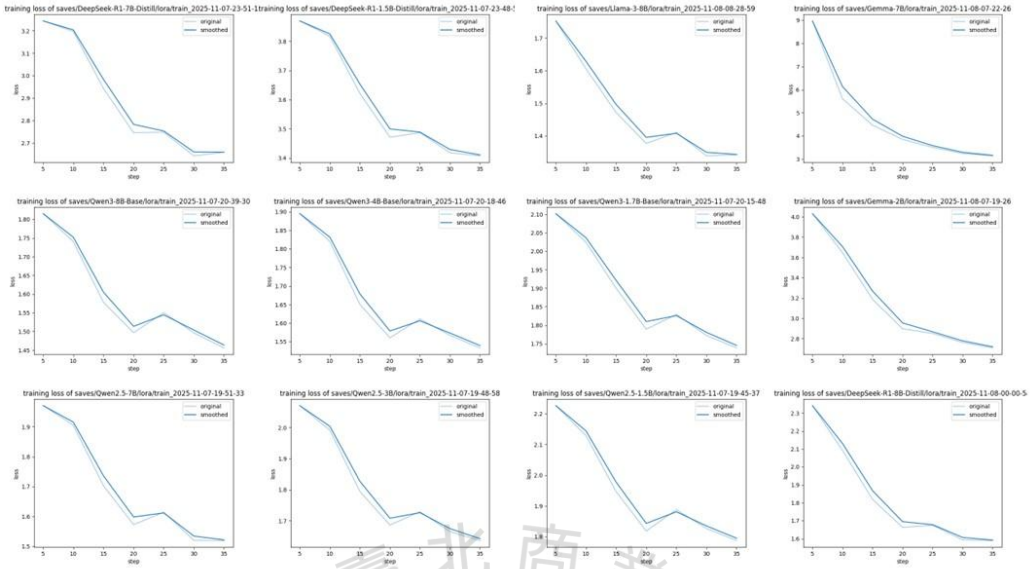

圖 3-2　微調模型訓練損失折線圖

資料來源：本研究者繪製

由上述訓練歷程圖可觀察到，所有模型在經過約 20 個 step 後，Training Loss 皆呈現顯著且穩定的下降趨勢，並在訓練後期趨於平緩收斂。這顯示模型已成功適應本研究建構之資安指令集資料分布。此外，透過觀察 Loss 曲線之平滑度，並未出現劇烈震盪或突然上升之情形，顯示在 LoRA 參數設定下，模型訓練過程穩定，未發生梯度爆炸或明顯的過擬合現象。此一收斂良好的訓練結果，為第四章模型在資安任務上的效能提升奠定了基礎。

綜上所述，本研究透過高品質資料集建構與合成資料增補策略，結合 LLaMA Factory 框架與 LoRA 微調技術，成功實現了多模型在資安法規語境下之高效訓練。此過程不僅確保了訓練效率與可重現性，亦為後續章節中模型表現分析與生成品質評估奠定基礎。

國立臺北商業大學 National Taipei University of Business NTUB 1917

第四節　檢索增強生成

為提供具個人化、語境適配性與組織規範一致性的資訊安全管理建議，本研究整合輕量化檢索增強生成架構 LightRAG（Guo et al., 2024）與單位專屬文件處理流程，建構一套能動態回應、低運算負擔、且具高彈性與可擴充性的知識支援系統[10]。

傳統的大型語言模型（LLMs）在面對專業領域問題時，往往受限於訓練語料缺乏領域知識與最新法規內容，導致生成結果出現「幻覺」（hallucination）或規範錯誤。檢索增強生成（RAG）技術則藉由「外部知識檢索（retrieval）」與「語境生成（generation）」的結合，使模型在回應前可先從知識庫中擷取相關資訊，從而提升內容之準確性與可追溯性。

LightRAG 為近年提出的高效 RAG 架構之一，其核心優勢在於模組化設計與輕量化運行成本。其檢索階段結合高效向量資料庫與語義相似度運算，生成階段則透過 API 與外部語言模型協作，使整體架構在保留語義精準度的同時，大幅降低硬體負擔，特別適合中小型組織或邊緣運算環境部署（edge deployment）。

本研究採用混合式知識庫設計（Hybrid Knowledge Base Design），將「通用標準知識」與「組織特定知識」進行結合，確保模型回應兼顧普適性與在地性。

通用知識層（Universal Knowledge Layer）：以國際公認之資安規範文件為核心，包括 ISO/IEC 27001、NIST Cybersecurity Framework、GDPR Compliance Guidelines 與 CIS Controls。此層提供高可信度之安全標準與法規依據，作為系統在缺乏內部文件時的基礎參考。

組織知識層（Organizational Knowledge Layer）：由使用單位自行上傳內部政策、作業規範、資安指引與管理程序等文件構成。此層內容反映組織實際運作環境，使系統能生成符合內部規範與風險管控需求之回應。

LightRAG 預設採用「固定長度重疊切分（fixed-size with overlap）」策略，將長篇文件分割為數個重疊片段以利向量化索引。切分後的文件片段經由 嵌入模型（embedding model） 轉換為高維語意向量後，儲存於向量資料庫中。當查詢輸入後，系統依據語義相似度進行檢索，擷取最具相關性的文件段落作為生成階段之提示語料（contextual prompt），以達成知識對齊與內容一致性。

為確保本系統可於實際環境中穩定運行，本研究採用 LightRAG Server API 作為主體推論與檢索介面。伺服器端以容器化環境部署，透過 RESTful API 實現文件索引、語意檢索及回應生成三大功能模組。其主要設定如下：

大型語言模型（LLM）：採用 qwen3:latest 作為生成核心。此模型具備優異的中英文雙語語義理解與長上下文處理能力，能在面對政策條文、技術規範與多層邏輯推論任務時維持高準確率與穩定性。

向量嵌入模型（Embedding Model）：選用 Qwen/Qwen3-Embedding-4B-GGUF，其在語意密度表徵與跨文件相似度運算上表現優異。該模型以 4B 參數規模達成嵌入效能與推論效率的平衡，能於單一 GPU 環境中穩定運作，適合學術與中小企業部署環境。

索引資料庫：系統使用向量索引機制儲存與檢索文件片段，支援 Top-k 近似相似度檢索與動態重建索引，確保文件更新後之查詢結果始終保持一致。

LightRAG Server 查詢流程包括：(1) 使用者輸入自然語言查詢；(2) 伺服器端呼叫嵌入模型生成查詢向量；(3) 在知識庫中檢索前 K 個相似文件片段；(4) 將檢索結果與查詢內容整合為最終提示語；(5) 傳遞至 qwen3 模型生成最終回應。此流程使系統在回應時同時具備語意依據與政策脈絡，提升內容可信度與合規性。

為驗證系統於實際場域中之效能與可行性，本研究以國立臺北商業大學之資安管理文件作為實驗資料來源，進行實際文件匯入與檢索流程建構。

這些文件涵蓋從資產管理、風險評估、應變程序到個資處理等多層面議題，

反映教育機構資訊安全治理的完整框架。

在實作中，研究者先將上述文件上傳至 LightRAG 系統，經過語義切分與嵌入處理後，系統自動建立索引並與通用資安文件整合成混合知識庫。

當輸入查詢（如：「請說明本校在個資異動時的授權審核程序」）時，LightRAG 透過 API 執行以下步驟：

1. 呼叫嵌入模型生成查詢向量；
2. 於向量資料庫中檢索與查詢最相關之段落；
3. 將檢索內容整合為語境提示（contextual prompt）；
4. 交由 qwen3:latest 模型生成結構化回應；
5. 回傳包含依據來源段落之完整答覆。

為確保知識內容之時效性，本系統設計「文件更新與索引重建」機制。當系統偵測文件版本更新、章節新增或刪除時，會自動觸發語義切分與向量重建程序，並同步更新檢索索引。此機制確保所有回應均基於最新版本文件生成，避免過期資訊導致誤導性建議。

此外，系統亦提供「動態權重調整（Dynamic Weighting）」功能，允許使用者設定通用文件與內部文件在檢索階段之權重比值，以便在不同任務場景下平衡標準依據與在地實務。例如，合規審核場景可提高 ISO 27001 與 NIST 文件權重，而內部作業諮詢則可強化組織文件的優先檢索比率。

綜合而言，本研究所建構之 LightRAG 架構與文件處理流程具備以下優勢：

- 高適配性（Adaptability）：結合通用資安標準與組織內部文件，確保生成內容同時滿足標準合規與個案需求。
- 高檢索精度（Retrieval Precision）：語義切分策略與先進嵌入模型有效提升文件語意對齊度，確保回應準確且脈絡一致。
- 低運算負擔（Computational Efficiency）：LightRAG 架構及 qwen3/Qwen3-Embedding 組合大幅降低推論延遲與 GPU 記憶體占用。

- 高可維護性（Maintainability）：文件更新機制與自動索引重建確保系統知識庫持續同步最新版本，支援長期部署。

透過上述設計，本系統不僅實現語意檢索與語境生成之深度融合，更進一步使語言模型回應內容具備個案適配性、政策一致性與運算可行性，達成組織級資安知識輔助系統之開發目標。

國立臺北商業大學
1917
NTUB
National Taipei University of Business

第四章　實驗結果

第一節　實驗資料集

本研究的實驗資料集主要由兩大類型構成，分別為用於模型語言能力調整的微調語料，以及用於知識檢索能力測試的檢索增強生成問答語料。兩者在來源、生成方式與使用目的上各有不同，但共同支撐整體模型訓練與評估流程，使研究能同時觀察模型在專業語境理解以及文件檢索問答兩方面的表現。

微調資料集主要包含 240 筆指令與回應配對資料。首先針對台灣資安法規，利用人機協作流程撰寫具有高精確性與專業性的指令與回答。這些資料以問答或任務指示的方式呈現，內容涵蓋定義說明、規範比較、制度流程解釋等多種資訊安全領域常見需求。為了提升資料量及豐富問題類型，研究中同時使用大型語言模型協助根據特定片段自動產生指令與回應，再由研究者逐一校對、修正語句或調整內容，使其完全符合原始文件的規範描述，不會出現偏離文件內容的推論或虛構資訊。整體資料經過格式化，使其在內容、語氣與句式上皆保持一致，能夠適合作為指令微調的訓練素材。

這份微調資料集除了是模型微調的主要來源之外，同時也擔任模型能力比較的基準資料。以相同的資料對預訓練模型與微調後模型進行回答測試，以檢驗微調是否確實強化模型對資訊安全領域語意、術語與邏輯的掌握程度。透過這樣的方式，本研究能在沒有檢索機制介入的條件下，單純觀察模型本身的語言能力提升幅度。

相比之下，RAG 問答資料集的目的在於評估結合檢索模組後的模型效能，其內容並未用於訓練，而是專門作為測試使用。這份資料集的來源是研究者所建立的資訊安全知識庫，當中包含資通安全管理法及其子法、ISO 27001 及相關技術文件、個資法指引、企業內部資訊安全政策與程序文件、教育訓練教材等內容。所有文件皆經過清理、切分與向量化處理，轉換為可被 RAG 系統檢索

的片段。接著，本研究以大型語言模型針對每個片段的內容自動產生相關的提問與答案，使問題能夠聚焦於片段中最具代表性或最核心的知識點，而答案則嚴格以片段本身的內容為依據，不依賴外部知識或背景推論。這樣的方式能確保生成結果與原始資料之間具有可檢驗的對應關係，使其適用於分析模型在檢索後能否忠實提取文件內容並產生正確回答。

為避免資料品質不一致，本研究在生成問答後仍進行人工審核，確認每一題的答案確實可由片段內容完整推導,並排除語意模糊或過度依賴推論的問題。資料也經過整理，使每組問答都能與來源片段精準連結，方便後續在分析檢索品質時作為比對依據。本研究最終建立的 RAG 問答資料集規模（待補充具體數量）足以涵蓋知識庫中主要概念，能夠有效反映模型在真實場景中處理知識檢索與引用的能力。

綜觀上述兩類資料集，微調資料集強化模型的語言理解與專業領域表達能力，並提供微調前後模型比較的依據；RAG 問答資料集則用於檢驗模型能否有效檢索與引用文件中的關鍵知識。兩者在研究設計中分別對應於模型能力的不同面向，使本研究得以在明確區分語言能力與檢索能力的前提下，更精確地分析模型效能，從而建立完整可靠的實驗結果基礎。

國立臺北商業大學 National Taipei University of Business NTUB

第二節　實驗比較對象

為系統性評估大型語言模型於本研究任務（資安法規導向之問答、合規建議與條文引用）之表現，本研究將比較對象分為三大類：(A) 預訓練模型（Base）、(B) 微調模型（FT）、(C) 微調模型＋RAG（FT+RAG）。三類比較旨在分離「參數內化（instruction tuning）」與「外部知識檢索（retrieval）」兩種來源對效能的貢獻，並據此回答：在法規密集與時效性要求的場景中，僅靠模型內化是否足夠？何時需要檢索增強生成以降低幻覺並提升可追溯性？

(A) 預訓練模型（Base）

選取具有代表性的開源模型作為基準（baseline），涵蓋不同架構與參數量級（1B－14B 為主）。此類模型未經本研究任務資料微調，僅保有通用語言能力。其用途在於量化微調與 RAG 所帶來的邊際效益。典型代表族群包含（舉例）：Llama 3.x、Qwen 2.5/3、Mistral 等。

(B) 微調模型（FT）

以 (A) 的同系列 Base 模型為初始化，採用指令微調（Instruction Tuning）使模型學得本研究域知識與任務格式（如：條文引用格式、合規風險分級、修正建議的層次化表述）。微調技術採 LoRA（Low-Rank Adaptation），以 LLaMA Factory 為主要訓練框架，兼顧參數效率與可重現性。透過高品質指令－回應資料集，強化模型於法規任務的準確率、可解釋度與格式一致性。

(C) 微調模型＋RAG（FT+RAG）

在 (B) 之上整合檢索增強生成：推論時對知識庫（含法規、制度、指引與案例）進行語義檢索，將高相關片段注入提示以提供明確上下文與可溯引用，目標是降低幻覺（hallucination）、提升可溯性（traceability）與時效性（timeliness）。此設計符合實務：組織需依據最新條文與內控規程產生合規決策，模型應以「可驗證之依據」支撐其建議。

在任務面向上，本研究聚焦於三大核心能力：(1) 法規理解與條文定位能力、(2) 合規建議生成與理由闡述能力、以及 (3) 法規依據之引用與可溯性能力。

首先，法規理解任務旨在評估模型能否正確辨識與問題相關之法條、條文結構及層級關係，並以適當語意摘要方式呈現關鍵義務。其次，合規建議生成任務考驗模型是否能根據輸入情境（如資安事件、組織等級、風險描述）生成具體且符合法規精神的建議，並清晰說明建議背後之理據。最後，引用與可溯性任務則評估模型能否於回答中提供正確的法源依據與條號標註，以反映其對原始知識的追溯能力與答案可驗證性。在此基礎上，本研究提出以下比較假說，作為後續實驗分析與統計檢定的理論依據：

1. H1（內化效益）：與 Base 相比，FT 在專業正確性、格式一致性、合規語氣與任務步驟化上顯著提升。
2. H2（檢索效益）：與 FT 相比，FT+RAG 在引用正確率與時效性場景（條文修訂、跨法域差異）顯著提升，並降低幻覺率。
3. H3（規模效應）：在等規模比較下，RAG 的增益可能高於單純放大參數量；在資源受限情境中，中小參數＋RAG 具更佳性價比。

綜上，透過上述任務劃分與假說設定，旨在驗證模型於專業正確性（accuracy）、語意一致性（consistency）、可溯性（traceability）與生成穩健性（robustness）等多維度上的差異。這些假說為實驗結果分析提供明確的檢驗方向，並作為第五章討論中評估不同模型架構適用性的理論基礎。

第三節　評估指標

為了全面評估語言模型生成內容的品質，本研究採用了多元的語意評估指標，以從不同面向衡量模型產生回應與參考答案之間的差異。這些評估指標包含傳統的 n 元語法重疊指標以及語意相似度指標，涵蓋精確度、召回率及語意匹配等面向，確保評估結果具有客觀性與廣泛性。主要指標說明如下：

- BLEU（Bilingual Evaluation Understudy）：BLEU 是機器翻譯領域經典的評估指標，透過比較模型輸出與參考譯文在字詞 n 元組上的重疊程度來衡量翻譯品質。其計算核心是評估生成文本中有多少字詞序列出現在參考文本中（強調精確匹配的比例），同時考量了長度懲罰以避免過短輸出帶來的不公平優勢。優點是計算方式直觀、可重複，對於用詞精確匹配度高的任務（如正式文件翻譯）有較好指標作用。然而，BLEU 偏重精確度（Precision），要求與參考答案字面匹配，當模型輸出使用同義替換或表達順序不同時，BLEU 分數可能低估實際品質。此外，BLEU 需要高品質的參考答案，對於開放式問答等可能存在多種正確回答的任務而言，單一參考答案的 BLEU 評分未必能充分反映模型表現[26]。
- ROUGE（Recall-Oriented Understudy for Gisting Evaluation）：ROUGE 最早用於自動摘要領域，著重評估模型輸出涵蓋參考答案資訊的程度，其核心衡量的是召回率（Recall）。ROUGE-N 通過計算生成文本與參考文本之間共有的 n 元組數量來度量重疊，ROUGE-L 則關注長度最長的公共子序列，以反映輸出是否包含參考答案中的長段落或關鍵序列。由於強調涵蓋率，ROUGE 適用於評估摘要或問答任務中模型是否完整提取了重點資訊。其優點是在多個參考答案或重點明確的情況下能較好地衡量內容覆蓋程度，與人工對「是否涵蓋要點」的判斷較為一致。但 ROUGE 同樣依賴於詞句表面重疊，無法有效辨識同義轉述；此外過於

追求召回可能導致模型傾向冗長輸出以囊括更多字詞，而評分未能懲罰無關冗語。因此，ROUGE 較適合作為內容覆蓋的指標，需搭配其他指標綜合解讀模型輸出品質[27]。

- BERTScore：BERTScore 是近年提出的語義評分指標，透過預訓練語言模型（如 BERT）的上下文向量表示來比較生成文本與參考文本的語義相似度。其做法是將輸出句子和參考句子的各個詞彙轉換為向量表示，計算兩者之間的餘弦相似度並配對彙總，從而評估輸出與參考在語意上的對齊程度。相較於 BLEU、ROUGE 僅關注表面詞彙匹配，BERTScore 利用深度語言模型捕捉語意與語境資訊，因而對同義轉換、措辭差異等更具穩定性。實證研究顯示 BERT Score 對判斷語意等價性更為敏感，在評估轉述、內容相關性方面表現優於傳統 n 元組指標。其優點還包括計算成本適中（只需向量計算）且對不同語域有較廣適用性。然而，BERTScore 也存在一些限制：由於依賴預訓練模型向量，其評分結果缺乏直觀可解釋性，無法像 BLEU 那樣直接指出錯漏的詞彙。另外，研究發現單純的向量相似度指標與人工評價之相關性有限，對細微語意差異或文本風格變化的捕捉仍不完善，且可能隱含預訓練模型的偏見。因此，BERTScore 提供了從語意匹配角度評估的新工具，但應結合人工分析與其他指標一同使用，以全面判斷模型輸出品質[28]。
- 語意相似度（Semantic Similarity）：語意相似度指標旨在衡量模型輸出與參考答案在整體語義上的接近程度，評估兩個句子所傳達意義的相似性。實作上常以將整句文本映射為向量（可透過 Sentence-BERT 等模型獲取句向量表示），再計算輸出與參考句向量的餘弦相似度來量化語意相近度。此類指標著重內容層面的匹配，能在一定程度上彌補 n 元組指標對詞彙多樣性的懲罰：即使模型輸出與參考答案用詞不同，但只要語意等價，向量相似度依然可能較高。因此，語意相似度有助於評

估開放問答中答案的正確性，特別是在存在同義表達或答案要點可以多種表述時，它提供了一種更貼近人類理解的相似性度量。此外，語意相似度計算通常實現簡單快捷，只需預備合適的語意嵌入模型即可。然而，該指標也有不足之處：一方面，純量的相似度分數缺乏明確解讀依據，無法指出模型輸出與參考答案差異的具體所在；另一方面，在答案不完整或包含多重要素的情況下，即使輸出僅涵蓋部分要點，語義相似度可能仍給出中等偏高的分數，掩蓋了內容遺漏的問題。因此，在應用語意相似度指標時，需要注意配合其他精細化指標一起分析。此外，有研究指出，此類基於向量的語意度量仍可能存在偏差和與人工評價不完全一致的情況。總體而言，語意相似度作為評估指標可提供模型輸出與標準答案在語義層面的匹配程度衡量，有助於了解模型在語意理解上的表現，但為求周延，本研究同時考量 BLEU、ROUGE 等傳統指標以及 BERT Score，共同形成多維度的評估機制。

- LLM-as-a-Judge 評分機制：除上述客觀自動化評估指標外，本研究進一步引入 LLM-as-a-Judge 作為補充性的主觀評分機制，以評估模型生成回應在整體品質與實務可用性上的表現。傳統自動化指標如 BLEU、ROUGE 與 BERTScore 主要衡量生成文本與參考答案之間的字詞或語意相似度，雖能提供量化比較依據，但較難完整反映回答在專業合理性、論述完整性、邏輯一致性以及是否符合實務情境需求等層面之品質差異。LLM-as-a-Judge 的核心概念在於利用大型語言模型模擬人類專家之評判行為，對模型輸出進行整體性評估。本研究採用同一評判模型（gpt5-mini），對不同模型配置所生成之回應進行一致性評分，以降低評分偏差並確保比較公平性。評分結果以平均分數作為分析依據，用以觀察不同訓練策略與檢索增強機制對生成品質之影響趨勢。需要特別說明的是，LLM-as-a-Judge 並非用以取代既有的客觀評估指標，而

是作為補充視角，從更貼近實務使用情境的角度，評估模型回答是否具備清楚結構、合理推論與專業一致性。透過結合客觀指標與 LLM-as-a-Judge 主觀評分結果，本研究得以更全面地分析不同模型配置在實際應用層面之整體表現。

國立臺北商業大學
1917
NTUB
National Taipei University of Business

第四節　實驗結果

本節本節將比較不同模型配置在合規任務測試集與知識問答測試集下的整體表現，並透過跨模型與跨指標的統計分析，系統性驗證指令微調（Instruction Fine-tuning）與檢索增強生成（Retrieval-Augmented Generation, RAG）對模型生成品質的實際影響。

為全面探討不同訓練策略的效益，本研究比較四種模型配置，包括預訓練模型（Pre-trained）、僅微調模型（Fine-tuned）、僅 RAG 模型（Pre-trained+RAG），以及同時結合微調與 RAG 的模型（Fine-tuned+RAG）。評估指標涵蓋 BLEU、ROUGE、BERTScore 與語意相似度，分別對應文字重疊程度、語意一致性與深層語意匹配能力。

首先探討在模型已具備領域指令能力的前提下，進一步加入檢索增強是否仍能帶來顯著效益。各模型於僅微調與微調＋RAG 兩種設定下的指標差異如圖 4-1 所示。

由圖 4-1 可觀察到，多數模型在加入 RAG 後，其語意相關指標（Semantic Similarity、BERTScore Recall）呈現一致性的正向提升。此現象顯示，即使模型已透過指令微調學習資安領域的任務格式與基本語意，仍可能因訓練資料規模有限，而在生成過程中遺漏部分關鍵資訊；RAG 所提供的外部知識能有效補足此不足，使模型回答在語意覆蓋與內容完整性上更為充分。

相較之下，在 ROUGE-1 與 ROUGE-L 等文本重疊指標上，部分模型的表現並未全面提升，甚至出現輕微下降。此結果顯示，RAG 引入的外部資訊雖提升語意正確性，但可能改變原本的句法結構，使生成文本不再僅追求與參考答案的字面重疊，而更偏向語意等價的表達方式。

整體平均提升趨勢如圖 4-2 所示，可觀察到不同模型在此比較下的效益並非完全一致，顯示模型規模與原始能力會影響 RAG 在微調後所能帶來的邊際

效益。

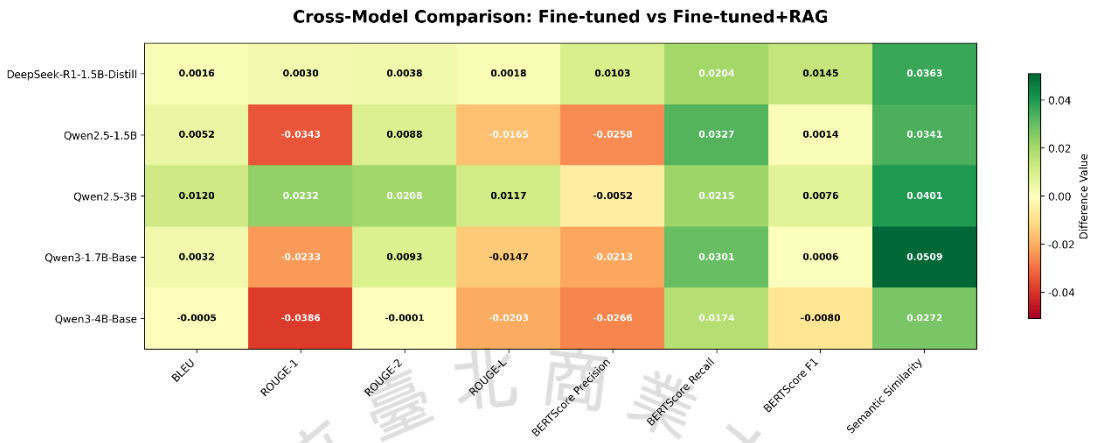

圖 4-1 微調模型與微調＋RAG 模型之跨模型指標差異熱圖

資料來源：本研究者繪製

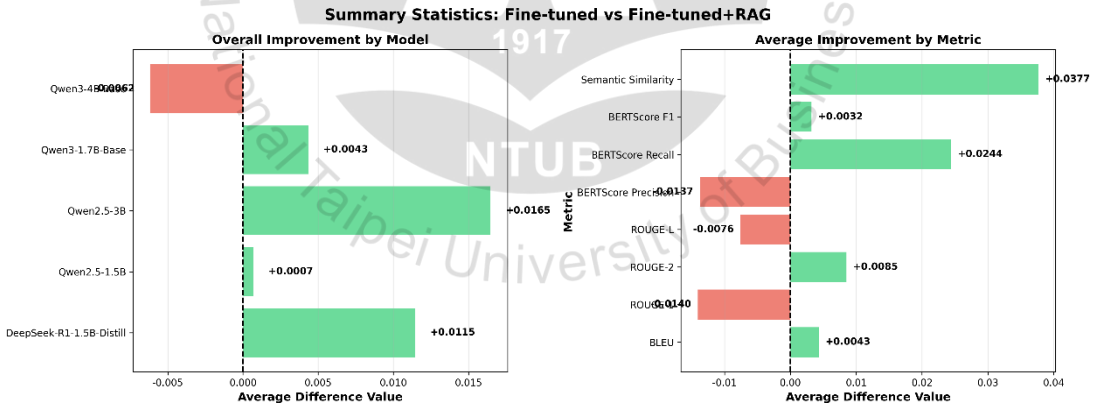

圖 4-2 微調模型與微調＋RAG 模型之整體平均提升統計

資料來源：本研究者繪製

為評估 RAG 在「未經任何指令微調」情境下的實際效果，本研究進一步比較預訓練模型與預訓練＋RAG 模型，其跨模型指標差異如圖 4-3 所示。

由圖 4-3 可明顯看出，所有模型在加入 RAG 後，於語意相似度與

BERTScore Recall 上皆呈現穩定且明確的正向提升。此結果顯示，即使模型未學習任何領域指令資料，RAG 仍能透過檢索外部知識，在生成階段補足模型內部知識的不足，使回答內容在語意層面更接近參考答案。

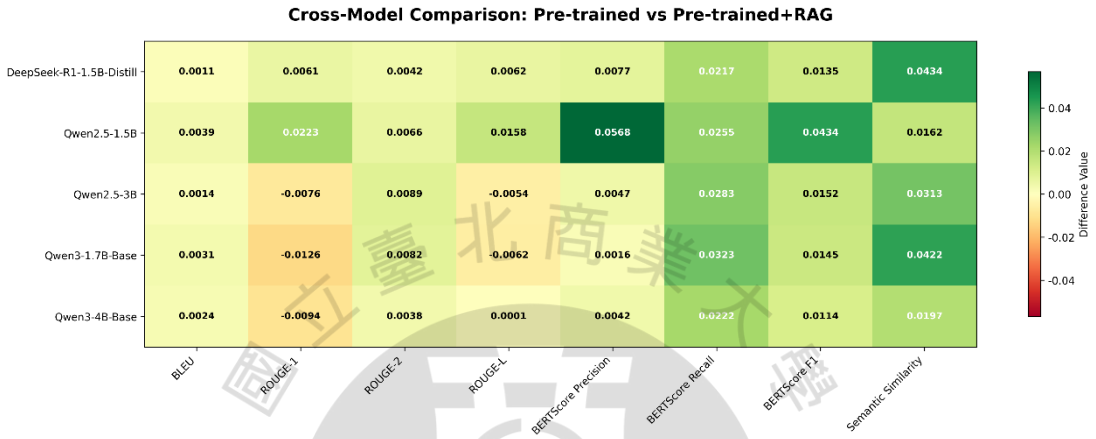

圖 4-3　預訓練模型與預訓練＋RAG 模型之跨模型指標差異熱圖

資料來源：本研究者繪製

值得注意的是，相較於微調情境，RAG 在此比較中的效益更為明顯，特別是對參數規模較小的模型而言。整體平均提升結果如圖 4-4 所示，小模型在此設定下的改善幅度普遍高於大型模型，顯示 RAG 對於內建知識容量有限的模型具有高度補償效果。

接著分析指令微調本身對模型效能的影響，透過比較預訓練模型與僅微調模型之生成品質差異，其結果如圖 4-5 所示。

由圖 4-5 可觀察到，微調對多數模型在 ROUGE-1、ROUGE-L 與 BERTScore Precision 等指標上具有顯著提升效果，顯示指令微調能有效幫助模型學習資安任務的問答格式、關鍵詞使用方式與專業術語表達。此結果反映微調資料雖數量有限，但其高度一致的任務結構與領域語意，能引導模型建立穩

定的回答模式。

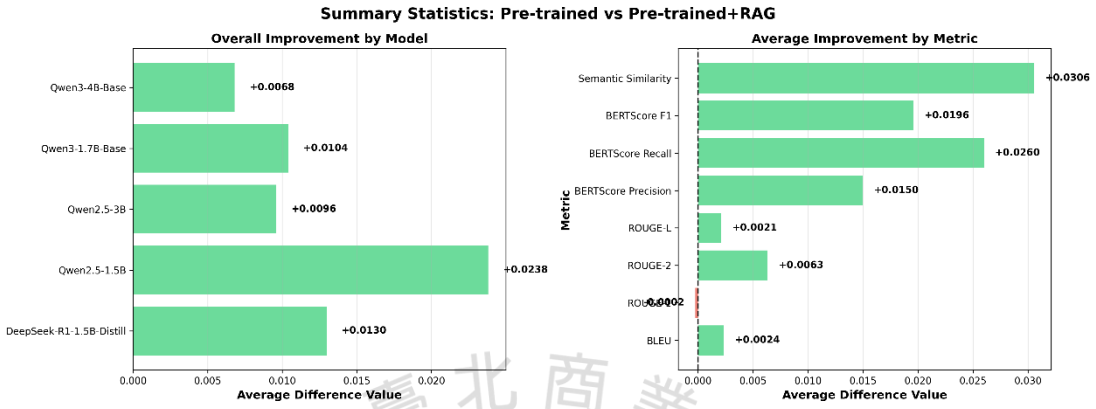

圖 4-4　預訓練模型與預訓練＋RAG 模型之整體平均提升統計

資料來源：本研究者繪製

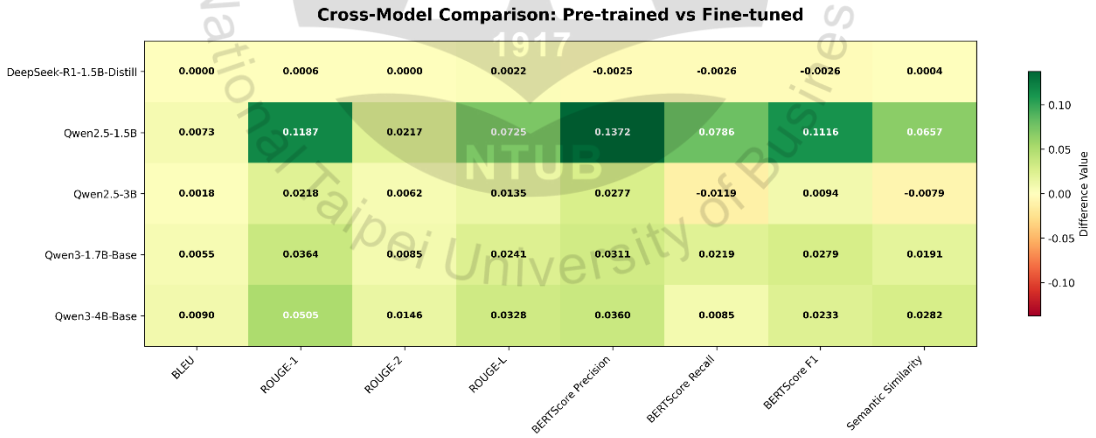

圖 4-5　預訓練模型與僅微調模型之跨模型指標差異熱圖

資料來源：本研究者繪製

然而，在部分語意相關指標上，微調所帶來的提升幅度相對有限，顯示僅依賴模型內部參數更新，仍可能無法完全涵蓋所有法規細節或知識型問題。其整

體平均趨勢如圖 4-6 所示，顯示微調對不同模型的影響程度具有明顯差異。

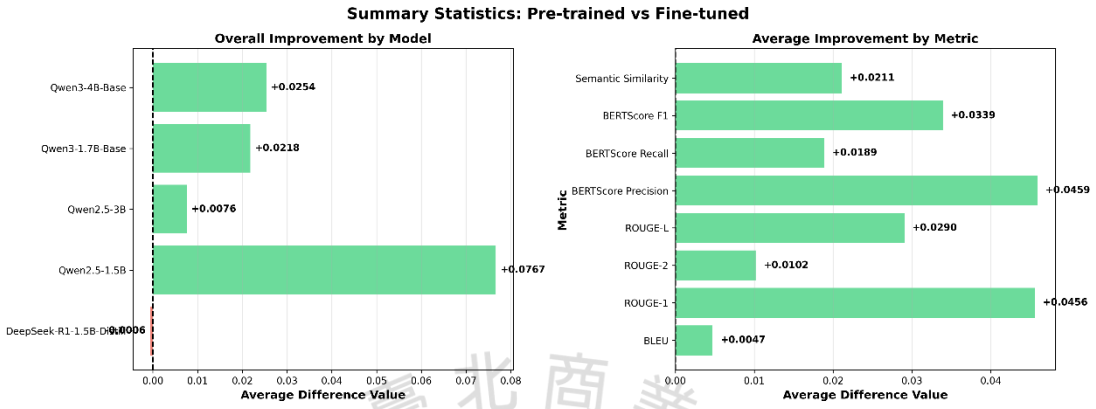

圖 4-6 預訓練模型與僅微調模型之整體平均提升統計

資料來源：本研究者繪製

在結合微調與檢索兩種技術後，本研究比較預訓練模型與微調＋RAG 模型的整體差異，其跨模型指標比較結果如圖 4-7 所示。

由圖 4-7 可觀察到，微調＋RAG 模型在幾乎所有模型與指標上皆呈現正向提升，且整體幅度明顯高於僅微調或僅 RAG 的情境。此結果顯示，微調與 RAG 在功能上具有高度互補性：微調使模型具備理解指令與領域語意的能力，而 RAG 則在生成階段動態補充最新或較為細節化的知識內容。

整體平均提升結果如圖 4-8 所示，顯示微調＋RAG 為本研究中整體表現最為穩定且最佳的模型配置。

最後，本研究比較預訓練＋RAG 模型與僅微調模型，以探討在無指令微調的情況下，RAG 是否能達成相近甚至更佳的效果，其結果如圖 4-9 所示。

由圖 4-9 可觀察到，對部分模型而言，僅透過 RAG 即可在 ROUGE 與 BERTScore Precision 等指標上超越僅微調模型，顯示 RAG 在知識補充與關鍵資訊引用方面具有顯著優勢。然而，在語意相似度與 BERTScore Recall 等指標

上，部分模型仍顯示微調具有不可取代的效果。

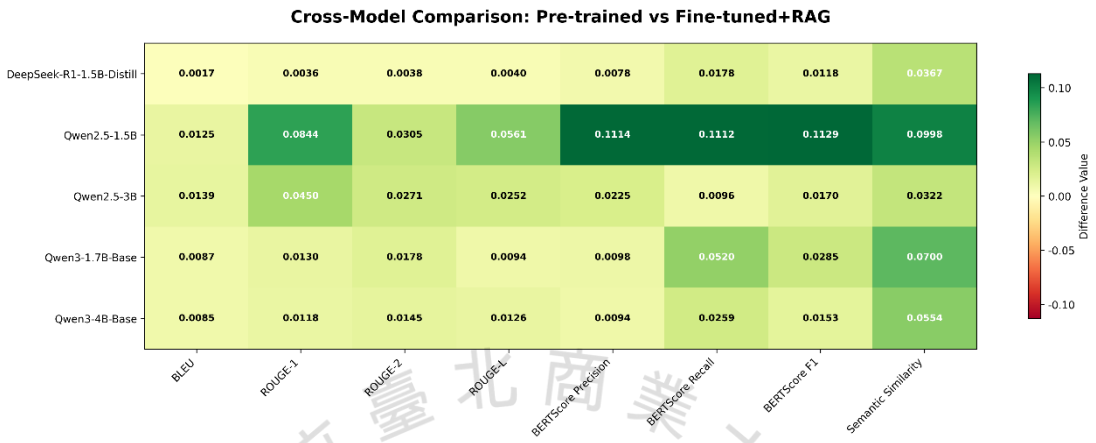

圖 4-7　預訓練模型與微調＋RAG 模型之跨模型指標差異熱圖

資料來源：本研究者繪製

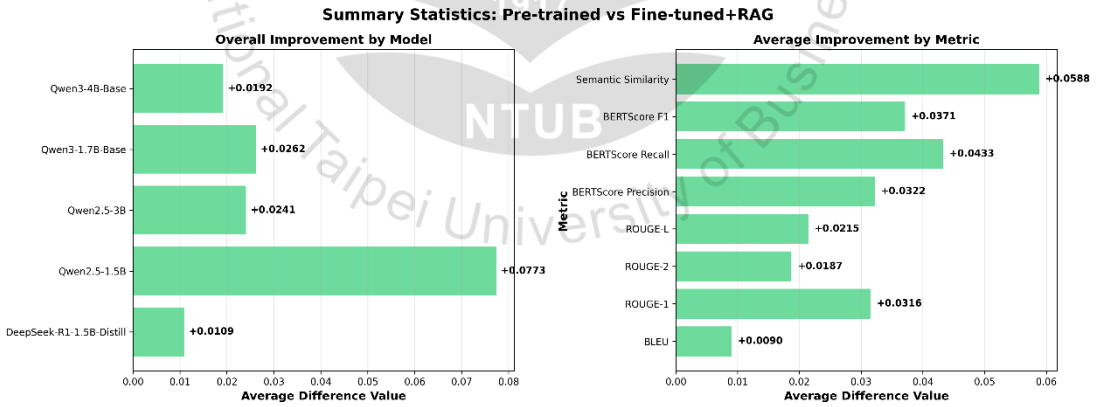

圖 4-8　預訓練模型與微調＋RAG 模型之整體平均提升統計

資料來源：本研究者繪製

整體平均趨勢如圖 4-10 所示，顯示 RAG 雖在部分情境下可作為微調的替代方案，但兩者在功能上仍具差異，難以完全互相取代。

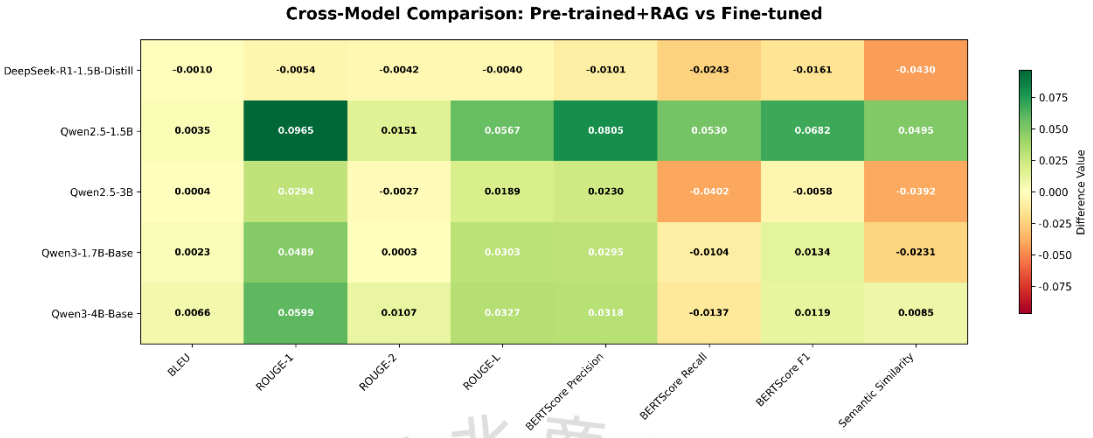

圖 4-9　預訓練＋RAG 模型與僅微調模型之跨模型指標差異熱圖

資料來源：本研究者繪製

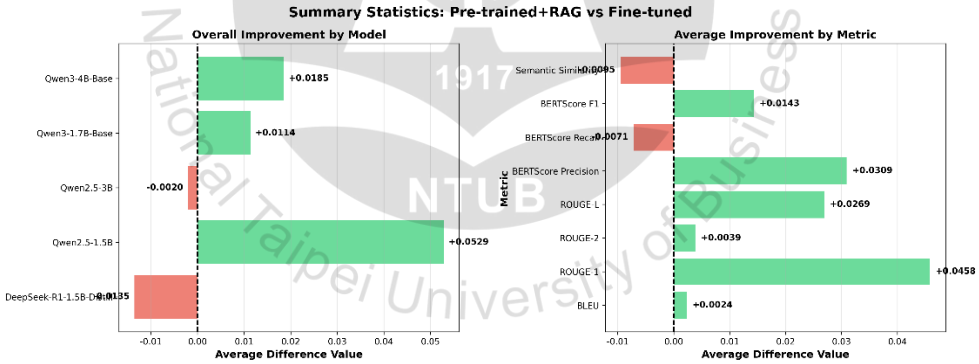

圖 4-10　預訓練＋RAG 模型與僅微調模型之整體平均提升統計

資料來源：本研究者繪製

為進一步從整體回答品質與實務可用性角度評估不同模型配置之表現，本研究採用 LLM-as-a-Judge 作為補充性評分機制，對各模型在不同設定下所生成之回應進行整體評分。圖 4-11 顯示不同模型於預訓練模型、預訓練模型+RAG、微調模型以及微調模型+RAG 四種配置下之平均 LLM-as-a-Judge 評分結果。

由整體趨勢可觀察到，多數模型在引入檢索增強生成（RAG）後，其平均評分皆呈現明顯提升，顯示外部知識檢索機制能有效改善模型回答之完整性與專業一致性。相較之下，僅進行指令微調（Fine-tuned）的模型，其評分提升幅度則相對有限，且在部分模型中未能明顯優於預訓練模型+RAG 設定，顯示在缺乏外部知識支援的情況下，單純依賴參數內化知識仍存在一定侷限。

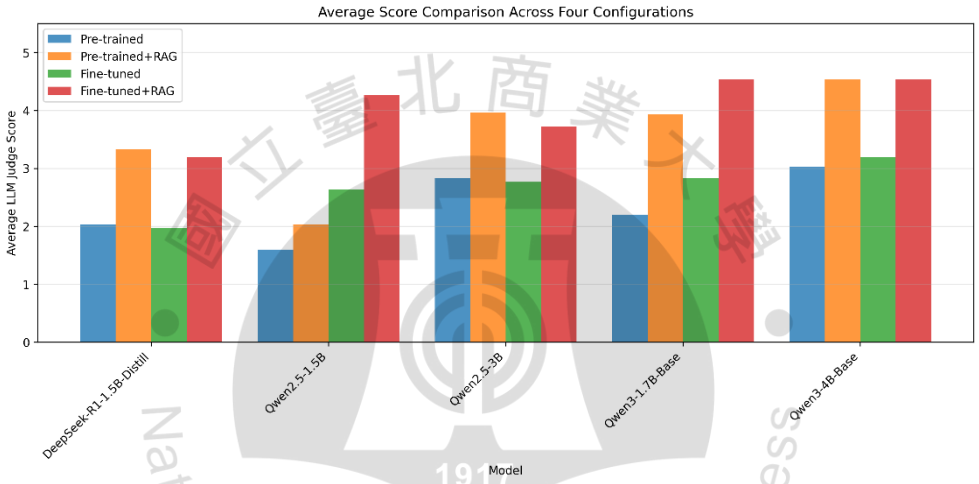

圖 4-11　LLM-as-a-Judge 評分結果

資料來源：本研究者繪製

進一步比較各配置間的分數差異，如圖 4-12 所示，可更清楚觀察不同訓練策略所帶來的影響。在「預訓練模型+RAG 相較於預訓練模型」的比較中，所有模型皆呈現正向差異，顯示即使未經指令微調，RAG 仍能穩定提升模型在 LLM-as-a-Judge 評估下的整體表現。而在「微調模型相較於預訓練模型」的比較中，分數差異則呈現不一致現象，部分模型甚至出現輕微下降，推測可能與微調資料規模有限或任務分布偏窄有關，導致模型泛化能力受限。

相較之下，「微調模型+RAG 相較於僅微調模型」在所有模型中皆展現穩定

且明顯的正向提升，顯示指令微調後引入檢索機制，能有效降低回答不完整或推論不足的情形，並提升模型整體回答品質。此外，於「微調模型+RAG 相較於預訓練模型+RAG」之比較中，多數模型仍呈現正向優勢，特別是在 Qwen 系列模型上，顯示指令微調有助於模型更有效地理解並整合檢索內容。

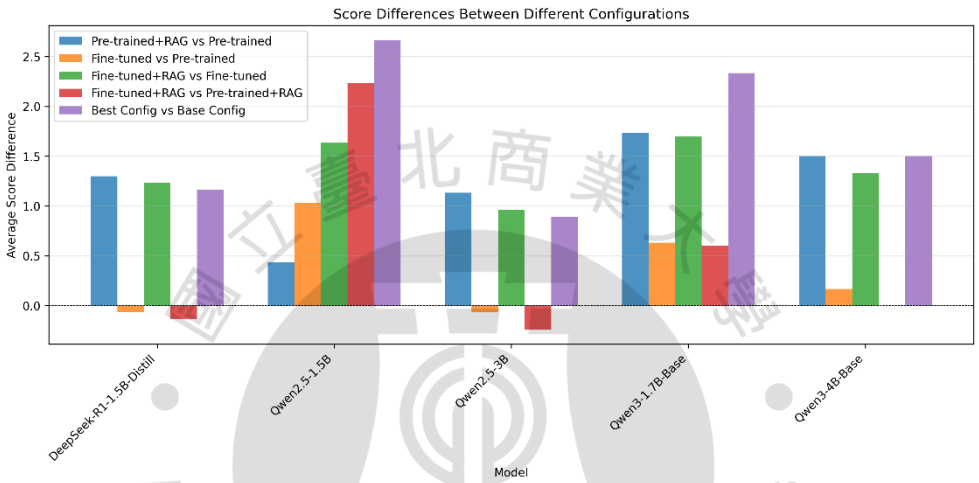

圖 4-12　LLM-as-a-Judge 評分差異比較

資料來源：本研究者繪製

整體而言，LLM-as-a-Judge 的評分結果與前述客觀指標分析趨勢一致，顯示結合指令微調與檢索增強生成之模型配置，在整體回答品質、專業合理性與實務可用性方面，皆能取得最為穩定且一致的表現。此結果進一步驗證本研究所提出之混合式架構，在實際應用情境下具備明確優勢。

綜合本節多組實驗結果可知，指令微調（Instruction Fine-tuning）與檢索增強生成（RAG）在資安合規與知識問答任務中各自扮演不可替代的角色，兩者所改善的模型能力面向具有明確差異，亦展現高度互補性。

首先，指令微調在本研究中主要負責建立模型對任務形式與領域語意的「結

構性理解能力」。透過微調資料集中一致的指令格式與資安法規語境，模型能學習如何解讀問題、組織回答結構，並在生成過程中適當使用專業術語與規範性語言。此能力反映於實驗中微調模型在 ROUGE 與 BERTScore Precision 等指標上的顯著提升（如圖 4-5 與圖 4-6 所示），顯示微調能有效提升模型對關鍵語意與答案結構的對齊程度。換言之，微調使模型「知道如何回答」，而非僅憑語言流暢度進行推測式生成。

然而，實驗亦顯示，僅依賴指令微調仍難以完全解決知識覆蓋不足的問題。由於微調資料規模有限，模型即使掌握了正確的回答框架，仍可能在細節法規條文、跨章節規範或情境化案例中產生資訊遺漏。此現象在語意相似度與 BERTScore Recall 等指標上尤為明顯，顯示模型在「知道怎麼回答」的同時，仍可能「不知道該引用哪些具體內容」。

相對而言，RAG 的核心價值在於彌補模型知識層面的不足，提供生成階段所需的即時且可更新資訊來源。實驗結果顯示，無論模型是否經過微調，只要結合 RAG，其語意相似度與 BERTScore Recall 皆呈現穩定提升（如圖 4-1、圖 4-3 所示），顯示檢索機制能有效協助模型涵蓋更多參考答案中的關鍵語意與知識脈絡。特別是在預訓練模型的情境下，RAG 能顯著降低模型對內部參數知識的依賴，使模型在未經大量訓練的前提下，仍能產出具備專業深度的回答。

然而，僅使用 RAG 而缺乏指令微調，亦存在其侷限性。實驗中可觀察到，部分模型在僅 RAG 設定下，雖能提升知識完整性，卻可能在回答結構、專業語氣一致性或合規邏輯組織上表現不穩定（如圖 4-9 與圖 4-10 所示）。此結果顯示，若模型本身未具備穩定的任務理解能力，即使檢索到正確資訊，仍可能無法有效轉化為符合任務需求的回答內容。

綜合上述分析，指令微調與 RAG 並非可互相取代的技術，而是分別對應模型能力中的「結構理解」與「知識補全」兩個關鍵層面。微調使模型具備正確解讀問題與組織答案的能力，而 RAG 則確保模型在生成過程中能取得完整、

正確且可追溯的外部知識。兩者結合後的微調＋RAG 模型，在所有比較中皆展現最穩定且全面的提升效果（如圖 4-7 與圖 4-8 所示），不僅在文本重疊與語意一致性指標上表現最佳，也在實際資安合規與法規問答情境中具備更高的可靠性。

因此，本研究實驗結果清楚支持以下結論：對於需要高度準確性、可解釋性與知識可追溯性的資安法規與合規任務，單獨使用指令微調或 RAG 均不足以達成最佳效果，唯有結合兩者，方能同時兼顧任務適配性與知識完整性，滿足實務應用需求。

國立臺北商業大學
1917
NTUB
National Taipei University of Business

第五章　結論與未來展望

第一節　結論

本研究以非資訊安全專業人員在面對資訊安全治理與法規遵循時所遭遇的理解落差為核心問題，探討人工智慧技術如何作為補強工具，協助一般使用者應對日益複雜的資安管理需求。過去相關研究大多著重於資安風險評估模型、攻擊偵測技術或規範管理流程，而較少關注「非專業使用者」在理解專業術語、查找法規依據與釐清制度要求時所面臨的實際困境。因此，本研究嘗試從認知落差與知識補強的角度切入，提出一套結合大型語言模型指令微調（Fine-tuning）與檢索增強生成（Retrieval-Augmented Generation, RAG）的 AI 資安輔助系統，以協助使用者在缺乏深厚資訊安全背景的情況下，仍能獲得可靠、準確、可追溯的安全建議。

本研究首先透過自建的資安領域微調資料集，使大型語言模型能掌握資訊安全常用術語、控制措施邏輯與合規語境。實驗結果顯示，各模型在微調過程中的損失函數均呈現穩定下降，且訓練集損失與驗證集損失之間的差距極小，證明模型並未出現過擬合現象，而是實質學習到可泛化的資安語意模式。這表示即便微調資料規模僅為 240 筆，若資料設計具備良好情境性與語意標示，仍能有效強化模型對專業領域的理解能力。跨模型比較亦發現，微調後的模型在語意理解、邏輯組織與回答一致性方面均顯著優於預訓練模型，印證了指令微調對於專業領域任務的重要性。

然而，在知識密度高、規範細節繁瑣的資訊安全領域中，單靠微調仍難以完全掌握所有法規條文與控制指引，同時每個單位或公司皆有自己的資安規範，且可能會頻繁變動，並不適合使用微調模型的方式讓大語言模型學習。為解決此問題，本研究進一步整合 RAG，使模型在生成過程中能即時檢索來源文件。從實驗結果可觀察到，RAG 對模型性能的提升並非局部或偶發，而是呈現一致

性與全面性的改善。BLEU、ROUGE、BERTScore 與語意相似度等指標皆顯著提升，顯示模型在加入 RAG 後能更完整地涵蓋參考答案中的邏輯結構與內容意涵。特別值得注意的是，本研究發現「文本切分策略」是 RAG 系統效能的關鍵決定因素。實驗證實，相較於傳統固定長度切分，採用針對法規結構設計的語意切分技術，能有效保留條文的完整性與跨段落邏輯，這是模型能夠精準引用正確法條的前提。此外，模型產生的回應更具可追溯性，能引用法規條文、政策段落或文件內容，使使用者能清楚理解建議的依據；這一特性大幅提升了回應的透明度與可信度，補強了語言模型在企業環境中常被質疑「黑盒化」的問題。

綜合微調結果與 RAG 效益，本研究提出的 AI 資安輔助系統展現了三項主要貢獻。首先，它成功降低了非專業使用者在理解資安概念與法規要求時的知識門檻，提供清晰、合規且具有教育意義的說明，使使用者能逐步建立正確的資安思維。其次，系統具備的資訊檢索能力使回答內容具備高度的事實性與準確性，不僅減少使用者查找資料的時間，也降低了模型可能產生錯誤建議的風險。第三，本研究的結果顯示，微調與 RAG 的組合可作為專業領域 LLM 應用的一般化架構，亦即「模型負責語意理解與語言組織；檢索模組負責知識準確性」，此架構對於所有法規、高知識密度或高度情境依賴的領域皆具普遍適用性。

總體而言，此系統成功達成研究目標，不僅有效縮小非專業人員在資訊安全領域的知識落差，也提供了一套具可靠性、可解釋性與實務價值的合規與決策輔助工具。透過微調提升語意掌握能力，搭配 RAG 增強資料正確性與引用能力，本研究示範了如何將大型語言模型轉化為組織內部可用、可信且能實際改善資訊安全治理流程的 AI 系統，也為未來大型語言模型在專業領域應用提出了一個具體且可行的典範。

然而，本研究仍存在部分研究限制。首先，本系統之知識範圍高度依賴於檢

索資料庫的完整性，對於零日攻擊（Zero-day exploits）或尚未寫入規範的新型態威脅，系統可能因缺乏檢索來源而無法提供具體防禦建議。其次，雖然 RAG 架構能確保留言的法規依據，但目前的系統定位為「諮詢顧問」，尚無法主動介接資安設備進行自動化阻擋或漏洞修補，此為實際應用於全自動化資安管理時的技術門檻。未來研究可朝向整合 API 以實現主動式防禦建議發展。

國立臺北商業大學
1917
NTUB
National Taipei University of Business

第二節　未來展望

儘管本研究已證實結合指令微調與 RAG 架構的 AI 資安輔助系統能有效協助非專業使用者提升合規判讀與資訊安全知識掌握能力，然而，仍有多項方向值得在未來加以深化與擴展，以強化系統的成熟度、擴充性與跨情境適用性。

首先，在資料面與知識維運層面，未來研究可著重於建立更大規模且具備動態更新能力的知識庫。資訊安全領域具有高度時效性，法規修訂、新興攻擊手法與組織政策的變更皆可能影響合規要求。為提高系統回答的可靠性，未來可導入自動化知識更新模組，透過監測政府公告、威脅情資來源與組織內部文件，以週期性同步知識庫內容。此外，亦可探索跨組織、多租戶的知識分層管理，使不同企業能在共通框架下維持獨立的政策文件與系統設定。同時，為因應全球化企業需求，系統可持續擴充至多語言環境，包括中英雙語或更多語言，讓不同語系的使用者皆能獲得一致且合規的安全建議。透過這些機制，系統將能更靈活地因應多變的安全情境並維持知識的即時性與完整性。

其次，本研究提出的架構具備高度的普適性，未來可將其應用拓展至其他高風險、高規範要求的專業領域，使系統價值不侷限於資訊安全範疇。例如在醫療領域中，可整合臨床指引、電子病歷與醫學標準，以協助醫護人員進行初步資訊判讀或流程決策；在法律領域中，可結合法規條文、判例資料庫與實務見解，使系統能提供初步的法規解釋輔助；在金融與保險產業中，亦可用於協助從業人員進行風控審查、稽核流程與合規檢查。不同領域雖需求不同，但同樣具有高度知識密度與合規要求，因此本研究架構中「微調負責語意理解、RAG 負責知識補強」的設計邏輯，具有跨領域移植的可行性。未來若能為不同領域量身打造知識庫與微調資料集，將可驗證本架構的廣泛適用性並探索各領域間的差異化需求。

第三，在模型架構與運算資源優化方面，未來研究亦有相當大的發展空間。

隨著多模態技術成熟，未來可考慮使系統具備處理文字以外資訊的能力，如分析網路拓樸圖、事件日誌截圖、系統設定畫面或 PDF 表格，讓系統能在更接近真實資安作業情境的環境中運作。同時，隨著長上下文模型（如長序列 Transformer、RNN-Transducer 或 Retrieval-based memory models）的進步，系統可望在處理長篇政策文件與跨對話輪次的任務中具備更強的資訊保留能力。此外，為提高系統適用性與降低硬體成本，未來可持續採用 LoRA、QLoRA 等參數高效微調技術，使模型能在更有限的運算條件下達成持續微調、領域擴展或知識更新。這些方向不僅能提升模型效能，也能減少企業部署的門檻，使系統更適合實際導入。

最後，為確保系統在真實場景中的有效性，未來研究建議導入更系統化的使用者測試與人因評估。透過將系統部署於企業環境並進行情境化實測，可蒐集使用者在真實作業流程中的互動行為、滿意度與使用痛點。例如記錄使用者是否能透過系統提高作業效率、是否更容易理解資安規範、以及系統建議是否影響其決策品質。同時，透過可用性評估（如 SUS、UEQ 或 TAM 模型）可更深入分析使用者對系統的信任度、易用性與學習曲線，作為改善提示設計、介面資訊架構或回應風格的重要依據。人因觀點的導入將有助於發現系統在實際應用中可能面臨的隱性問題，使後續開發更符合終端使用者需求並提高系統整體採用率。

綜合以上觀察，本研究所提出之結合微調與檢索增強生成的 AI 資安輔助架構已在功能性與可行性上展現良好成果，但仍具有持續進化的空間。隨著資料擴充、跨領域應用、多模態整合、模型效能優化與人因評估的逐步推動，未來的系統將能更具廣度、深度與彈性。此一研究方向不僅可望成為企業資訊安全治理的重要輔助工具，同時也將為大型語言模型在其他高規範場域落地應用奠定具有代表性的示範基礎，持續推動人工智慧在專業領域的實務轉型。

參考文獻

[1] Check Point Research. (2024). A closer look at Q3 2024: 75% surge in cyber attacks worldwide. Check Point Research Blog, 1–1. Retrieved from https://blog.checkpoint.com/research/a-closer-look-at-q3-2024-75-surge-in-cyber-attacks-worldwide/

[2] Ji, Z., Lee, N., Frieske, R., Yu, T., Su, D., Xu, Y., … & Fung, P. (2023). Survey of hallucination in natural language generation. ACM Computing Surveys, 55(12), 1-38.

[3] Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., … & Kiela, D. (2020). Retrieval-augmented generation for knowledge-intensive nlp tasks. Advances in Neural Information Processing Systems, 33, 9459-9474.

[4] Gillioz, A., Casas, J., Mugellini, E., & Abou Khaled, O. (2020, September). Overview of the Transformer-based Models for NLP Tasks. In 2020 15th Conference on computer science and information systems (FedCSIS) (pp. 179-183). IEEE.

[5] Zhou, C., Li, Q., Li, C., Yu, J., Liu, Y., Wang, G., … & Sun, L. (2024). A comprehensive survey on pretrained foundation models: A history from bert to chatgpt. International Journal of Machine Learning and Cybernetics, 1-65.

[6] Thirunavukarasu, A. J., Ting, D. S. J., Elangovan, K., Gutierrez, L., Tan, T. F., & Ting, D. S. W. (2023). Large language models in medicine. Nature medicine, 29(8), 1930-1940.

[7] Lai, J., Gan, W., Wu, J., Qi, Z., & Philip, S. Y. (2024). Large language models in law: A survey. AI Open.

[8] Huang, L., Yu, W., Ma, W., Zhong, W., Feng, Z., Wang, H., … & Liu, T. (2023). A

survey on hallucination in large language models: Principles, taxonomy, challenges, and open questions. ACM Transactions on Information Systems.

[9] Edge, D., Trinh, H., Cheng, N., Bradley, J., Chao, A., Mody, A., … & Larson, J. (2024). From local to global: A graph rag approach to query-focused summarization. arXiv preprint arXiv:2404.16130.

[10] Guo, Z., Xia, L., Yu, Y., Ao, T., & Huang, C. (2024). Lightrag: Simple and fast retrieval-augmented generation.

[11] Ding, N., Qin, Y., Yang, G., Wei, F., Yang, Z., Su, Y., … & Sun, M. (2023). Parameter-efficient fine-tuning of large-scale pre-trained language models. Nature Machine Intelligence, 5(3), 220-235.

[12] Kelvin Guu, Kenton Lee, Zora Tung, Panupong Pasupat, and Ming-Wei Chang. 2020. REALM: retrieval-augmented language model pre-training. In Proceedings of the 37th International Conference on Machine Learning (ICML'20), Vol. 119. JMLR.org, Article 368, 3929–3938.

[13] Izacard, G., & Grave, E. (2021). Leveraging passage retrieval with generative models for open domain question answering. Proceedings of the 16th Conference of the European Chapter of the Association for Computational Linguistics: Main Volume, 874–880. Association for Computational Linguistics.

[14] Borgeaud, S., Mensch, A., Hoffmann, J., Cai, T., Rutherford, E., Millican, K., Van Den Driessche, G. B., Lespiau, J.-B., Damoc, B., Clark, A., De Las Casas, D., Guy, A., Menick, J., Ring, R., Hennigan, T., Huang, S., Maggiore, L., Jones, C., Cassirer, A., Brock, A., Paganini, M., Irving, G., Vinyals, O., Osindero, S., Simonyan, K., Rae, J., Elsen, E., & Sifre, L. (2022). Improving language models by retrieving from trillions of tokens. Proceedings of the 39th International Conference on Machine Learning, 162, 2206–2240. PMLR.

[15] Gautier Izacard, Patrick Lewis, Maria Lomeli, Lucas Hosseini, Fabio Petroni, Timo Schick, Jane Dwivedi-Yu, Armand Joulin, Sebastian Riedel, and Edouard Grave. 2023. Atlas: few-shot learning with retrieval augmented language models. J. Mach. Learn. Res. 24, 1, Article 251 (January 2023), 43 pages.

[16] Shuster, K., Poff, S., Chen, M., Kiela, D., & Weston, J. (2021). Retrieval augmentation reduces hallucination in conversation. Findings of the Association for Computational Linguistics: EMNLP 2021, 3784–3803. Association for Computational Linguistics

[17] Lialin, V., Deshpande, V., Yao, X., & Rumshisky, A. (2024). Scaling down to scale up: A guide to parameter-efficient fine-tuning. arXiv.

[18] Parthasarathy, Venkatesh & Zafar, Ahtsham & Khan, Aafaq & Shahid, Arsalan. (2024). The Ultimate Guide to Fine-Tuning LLMs from Basics to Breakthroughs: An Exhaustive Review of Technologies, Research, Best Practices, Applied Research Challenges and Opportunities. 10.48550/arXiv.2408.13296.

[19] Wen, Z., Zhang, J., & Fang, Y. (2024). SIBO: A simple booster for parameter-efficient fine-tuning. Findings of the Association for Computational Linguistics: ACL 2024, 1241–1257. Association for Computational Linguistics.

[20] Hu, E. J., Shen, Y., Wallis, P., Allen-Zhu, Z., Li, Y., Wang, S., Wang, L., & Chen, W. (2022). LoRA: Low-rank adaptation of large language models. International Conference on Learning Representations.

[21] Dettmers, T., Pagnoni, A., Holtzman, A., & Zettlemoyer, L. (2023). QLORA: Efficient finetuning of quantized LLMs. Proceedings of the 37th International Conference on Neural Information Processing Systems (NeurIPS 2023), Article 441, 10088–10115. Curran Associates, Inc.

[22] Zhao, J., Ji, Z., Qi, P., Niu, S., Tang, B., Xiong, F., & Li, Z. (2024). Meta-chunking:

Learning efficient text segmentation via logical perception.

[23] Fan, Y., Yan, Q., Wang, W., Guo, J., Zhang, R., & Cheng, X. (2025). TrustRAG: An information assistant with retrieval augmented generation. arXiv.

[24] Liu, H., Wang, Z., Chen, X., Li, Z., Xiong, F., Yu, Q., & Zhang, W. (2025). HopRAG: Multi-hop reasoning for logic-aware retrieval-augmented generation. Findings of the Association for Computational Linguistics: ACL 2025, 1897–1913. Association for Computational Linguistics.

[25] Zheng, Y., Zhang, R., Zhang, J., Ye, Y., Luo, Z., Feng, Z., & Ma, Y. (2024). LlamaFactory: Unified efficient fine-tuning of 100+ language models. Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 3: System Demonstrations). Association for Computational Linguistics.

[26] Papineni, K., Roukos, S., Ward, T., & Zhu, W.-J. (2002). Bleu: A method for automatic evaluation of machine translation. Proceedings of the 40th Annual Meeting of the Association for Computational Linguistics, 311–318. Association for Computational Linguistics.

[27] Lin, C.-Y. (2004). ROUGE: A package for automatic evaluation of summaries. Text Summarization Branches Out, 74–81. Association for Computational Linguistics.

[28] Zhang, T., Kishore, V., Wu, F., Weinberger, K. Q., & Artzi, Y. (2019). BERTScore: Evaluating text generation with BERT. arXiv.

國立臺北商業大學 National Taipei University of Business NTUB 1917